



燕山大学
YANSHAN UNIVERSITY

硕士学位论文

MASTER'S DISSERTATION

(专业学位)

论文题目 面向癫痫脑电信号的机器学习分类方法
研究

作者姓名 任治宇

学科专业 通信工程(含宽带网络、移动通信等)

指导教师 李朝辉 教授

2023 年 5 月

中图分类号：TP391

学校代码：10216

UDC：621.39

密级：公开

专业学位硕士学位论文

面向癫痫脑电信号的机器学习分类方法研究

硕 士 研 究 生：任治宇

导 师：李朝辉 教授

副 导 师：王国宾 高级工程师

申 请 学 位：电子信息硕士

学 科 专 业：通信工程(含宽带网络、移动通信等)

所 属 学 院：信息科学与工程学院

答 辩 日 期：2023 年 5 月

授予学位单位：燕山大学

A Dissertation in Communication Engineering

STUDY ON MACHINE LEARNING METHOD FOR EPILEPSY EEG CLASSIFICATION

by Ren Zhiyu

Supervisor: Professor Li Zhaohui

Yanshan University

May, 2023

摘 要

癫痫是一种由大脑中神经元过度放电而引起的神经系统疾病，具有突发性和反复性等特点。利用脑电图进行癫痫发作检测对于诊断和治疗具有重要意义。临床上一般由医生对脑电图进行人工解读和分析。这种方法不仅耗时，而且易受医生个人主观因素的影响，存在诊断不及时、误诊漏诊的情况。所以研究癫痫发作自动检测方法具有一定的实用价值。

首先，对脑电信号及特征进行了阐述，并从时域、频域、时频域和非线性动力学四个方面重点分析了脑电信号的特征提取方法，比较了当前应用较为广泛的几种脑电信号特征提取方法的优点与不足，总结了机器学习的癫痫发作检测和分类方法，为后续设计癫痫发作自动检测方法奠定了理论基础。

其次，构建了一种多域联合分析的特征提取方法。结合双谱和连续小波变换算法对脑电信号子频段进行有效的动力学分析，以获得具有高区分度的特征，然后利用基于树的特征选择算法确定贡献最大的特征并使用多层感知器进行分类。为了证明方法的有效性，使用波恩大学癫痫脑电数据集进行 10 折交叉验证，结果表明多域联合特征提取算法均优于其他算法的分类性能。

最后，实现了一种基于注意力机制的时间卷积网络，用于癫痫脑电信号分类。通过在时间卷积网络中加入多头自注意力机制以提取脑电信号的有效信息，提高分类效果，使用基于卷积的滑动窗口进行并行化处理减少了计算量。在波恩大学癫痫脑电数据集进行训练与测试，在所有二分类任务中均达到了 100% 的准确率，三分类任务中获得了 98.67% 的准确率，说明了该方法在癫痫分类问题上具有一定的优越性。

关键词：癫痫；脑电图；双谱分析；连续小波变换；时间卷积网络；注意力机制

Abstract

Epilepsy is a kind of nervous system disease caused by excessive discharge of neurons in the brain, which has the characteristics of paroxysm and repetition. The detection of epileptic seizures by EEG is of great significance for diagnosis and treatment. In clinical practice, EEG is generally interpreted and analyzed manually by doctors. This method is not only time-consuming but also easily affected by the subjective factors of doctors. There are some cases of delayed diagnosis, misdiagnosis, and missed diagnosis. Therefore, the research on the automatic detection method of seizures has a certain practical value.

First of all, the EEG and its characteristics are described, and the feature extraction methods of EEG are analyzed from four aspects: time domain, frequency domain, time-frequency domain, and nonlinear dynamics. the advantages and disadvantages of several widely used EEG feature extraction methods are compared, and the seizure detection and classification methods of machine learning are summarized, which lays a theoretical foundation for the subsequent design of automatic seizure detection methods.

Secondly, a feature extraction method based on multi-domain joint analysis is constructed. Combined with bispectrum and continuous wavelet transform algorithm, the dynamic analysis of the subband of brain telecommunication signal is carried out effectively in order to obtain the features with high distinguish. then the tree-based feature selection algorithm is used to determine the features with the greatest contribution and multi-layer perceptron is used for classification. In order to prove the effectiveness of the method, 10-fold cross-validation was carried out using the epileptic EEG data set of the University of Bonn. The results show that the classification performance of multi-domain joint feature extraction algorithms is better than other algorithms.

Finally, a time convolution network based on the attention mechanism is implemented for epileptic EEG classification. The multi-head self-attention mechanism is added to the time convolution network to extract the effective information of EEG signals and improve the classification effect. The amount of computation is reduced by using the convolution-based sliding window for parallelization. When trained and tested in the epileptic EEG data

set of the University of Bonn, 100% accuracy was achieved in all two classification tasks and 98.67% accuracy in three classification tasks, indicating that this method has certain advantages in epilepsy classification.

Keywords: epilepsy; electroencephalography; bispectrum; continuous wavelet transform; temporal convolutional network; attention mechanism

目 录

第 1 章 绪论.....	1
1.1 课题研究背景.....	1
1.2 国内外研究现状.....	2
1.3 研究内容与结构安排.....	4
第 2 章 脑电信号及癫痫检测方法	6
2.1 脑电信号及特征.....	6
2.2 癫痫脑电信号的特征提取方法	8
2.3 机器学习分类方法.....	10
2.4 深度学习分类方法.....	11
2.5 本章小结.....	15
第 3 章 基于多域联合分析的癫痫分类方法	16
3.1 引言.....	16
3.2 实验内容.....	16
3.2.1 波恩脑电数据集.....	16
3.2.2 实验流程.....	17
3.3 多域联合分析方法.....	19
3.3.1 双谱分析方法及特征.....	19
3.3.2 连续小波变换及特征.....	24
3.3.3 特征选择方法.....	27
3.3.4 多层感知器.....	28
3.4 评估指标.....	30
3.5 实验结果.....	31
3.5.1 特征选择结果.....	31
3.5.2 分类器性能的比较.....	32
3.5.3 不同特征提取方法的性能比较.....	33
3.5.4 混淆矩阵.....	34
3.5.5 与其他方法的比较.....	35
3.6 本章小结.....	36
第 4 章 基于时间卷积网络的癫痫分类方法	37
4.1 引言.....	37
4.2 注意力时间卷积网络模型	37
4.2.1 预处理.....	39
4.2.2 卷积模块.....	39
4.2.3 基于卷积的滑动窗口模块.....	40

4.2.4 注意力模块.....	41
4.2.5 时间卷积模块.....	44
4.3 实验内容及参数.....	46
4.4 评估指标.....	47
4.5 实验结果.....	47
4.5.1 注意力头部数量的选择.....	47
4.5.2 损失函数.....	48
4.5.3 分类结果分析.....	48
4.5.4 混淆矩阵.....	49
4.5.5 与现有算法对比.....	50
4.6 本章小结.....	51
结论.....	52
参考文献.....	54

第1章 绪论

1.1 课题研究背景

癫痫是一种常见的慢性神经系统和非传染性疾病，影响全球6000至7000万人^[1]。癫痫可以在任何年龄段出现，但在婴儿和老年人中发病率较高，每年约有三百万人患上这种疾病^[2]。癫痫发作时脑电活动突然异常，常表现为大脑皮层神经元网络过度放电。癫痫有许多不同的形式，症状因人而异。大约四分之三的癫痫患者能够通过药物和手术的方式抑制癫痫发作。然而，约四分之一的患者即使接受了治疗，仍会继续癫痫发作。需要注意的是，鉴于癫痫病症的复杂性，癫痫发作很难预测，对于一些患者来说，一天内可能会有数百次癫痫发作，这对大脑造成不可逆转的损害。因此，及时检测和治疗对于控制癫痫的发展和提高患者的生活质量具有重要意义。目前基于脑电图^[3]、脑磁图^[4]、正电子发射断层扫描^[5]、单光子发射计算机断层扫描^[6]、功能性磁共振成像^[7]、皮层脑电图^[8]和功能近红外光谱^[9]等多种方法已经开展了多项有关癫痫监测的研究。

神经专家将癫痫发作分为两大类：部分性发作和全面性发作。部分性发作可以根据其症状来定义，主要是由于大脑单个位置引起的癫痫发作，而全面性发作涉及到大脑双侧半球^[10]。此外，部分性发作还可以分为两大类：简单部分性发作和复杂部分性发作。在简单部分性发作中，患者看起来有意识，一般可以交流，而在全面性发作中，患者行为异常，典型的行为方式是咀嚼和喃喃自语^[11]。全面性癫痫发作可以通过明显的运动体征来诊断，根据症状的不同，又可以分为失神发作、肌阵挛发作、强直阵挛发作和全面性意识障碍发作等。在癫痫发作检测任务中，神经科医生从脑电信号所反映的信息中进行分析 and 诊断，如波形、频率和幅度，因为癫痫发作中的脑电信号会表现出一些特殊的指标，如尖波、棘波或复合波。然而，仅依靠临床医生的目测，实现癫痫发作的有效检测往往是一项费时费力的任务，人为错误的可能性很高。具体而言，人工癫痫诊断受到以下方面的限制：

要求医师具有丰富的临床诊断经验和专业技能，主观性强，容易误诊。此外，不同的临床医生可能根据他们的经验对相同的脑电信号得出不一致的结论。

脑电信号是一种弱电生理信号，易受到噪声的干扰，信噪比低。被噪声干扰的脑电信号可能会出现波形变化，从而使诊断变得困难。

诊断癫痫所需的脑电信号数量较多。在临床环境中,脑电信号通常与视频信号同步记录,结合一些行为指标帮助诊断,这进一步增加了临床医生的工作量。据研究临床医生至少需要 16 个小时来查看患者的脑电信号才能做出诊断^[12]。在临床环境中,脑电检查的中断和繁重的工作量极大地影响了临床医生对信号的判断,从而可能导致误诊。

基于上述局限性,亟待寻找一种解决这些问题的办法。随着人工智能的发展,基于机器学习的自动检测技术给出这一问题的解决办法。近年来,机器学习技术在疾病临床诊断中得到了广泛应用,特别是在癫痫发作方面。这些机器学习技术极大减轻了临床医生的工作负担,提供了客观准确的诊断,显著提高了诊断效率。

1.2 国内外研究现状

癫痫发作自动检测技术起始于 20 世纪 70 年代。在早期的研究中,人们根据癫痫发作时的异常脑电信号波形来进行判别,如波形幅值的突增。在癫痫发作自动检测的相关工作中,遵循一个标准的范式:首先进行预处理(包括去伪迹、滤波和对原始信号加窗等步骤),然后特征提取获得主要信号特征,最后将所获得的特征馈送到分类器进行分类。现有文献中已经提出了许多用于癫痫脑电信号自动检测的方法。

在特征提取方面,癫痫脑电信号自动检测方法可以分为时域、频域、时频域和非线性动力学四大类。国内外学者基于这四个大类提出了多种方法提取癫痫脑电特征,例如经验模态分解^[13]、小波变换^[14]、功率谱密度分析^[15]、基于熵的方法^[16,17]、递归图^[18]和 Lyapunov 指数^[19]等分析方法。

对于特征提取,频域分析主要是在频域内计算脑电信号的能量。最具代表性的特征是功率谱分析,它可以通过非参数方法(例如,快速傅立叶变换)或参数方法来估计。然而,传统的频域分析仅估计信号的频谱内容,而没有考虑脑电信号的非平稳性。小波变换由于其突出的时频特色广泛应用于脑电信号分析,小波变换在低频时可以提供良好的频率分辨率,在高频时可以提供良好的时间分辨率。例如, Kulkarni 等人根据小波系数得到均值和方差对脑电信号进行分类^[20]。Gupta 等人利用柔性解析小波变换将脑电信号分解为 15 个级,以计算熵特征^[21]。虽然,时频分析可以获得大脑的非平稳信息,但是它无法捕捉到脑电信号分量之间的非线性动态变化。越来越多的研究表明,大脑是一个复杂的非线性动力学系统,脑电信号分量之间存在非线性耦合现象。双谱分析作为检测这种变化的另一方法,它保留了信号的相位信息,具有从高斯

信号中提取信息偏差的能力。Chua 等人将双谱特征应用于癫痫分类中,分别提取了功率谱特征和双谱特征。实验结果表明了使用基于双谱特征的分类精度(92.56%)优于传统功率谱特征的分类精度(88.78%)^[22]。Assi 等人从癫痫犬的脑电信号中划分了 30 秒非重叠窗口,提取归一化双谱熵和归一化双谱平方熵对发作前和发作间期的脑电信号进行分类,获得了 78.11%的分类精度,进一步验证了基于双谱特征进行癫痫发作预测的可行性^[23],但分类精度有待改进。

随着癫痫检测技术的不断进步,如何提高癫痫脑电分类准确度成为了近年来广大研究人员关注的重点,现存的检测算法各有优缺点。为了克服分类精度低的问题,一些研究通过更改算法的参数以获得更高的准确度;一些研究通过滤除掉干扰分类效果的伪迹以获得更纯净的脑电信号;一些研究通过改进算法以提取更为精良的特征值。但由于脑电信号的特殊性加之每个算法不同的特性,传统的特征方法在单一变换域下对脑电信号进行特征提取,总是不能提取全面的特征信息,容易造成信息的丢失。最近研究者越来越青睐于多种分析方法的结合,这样能有效的提取脑电信号的特征。例如,Bhuiyan 等人在小波分析的基础上,提出了一种经验模态分解和离散小波变换相结合的癫痫分类方法^[24]。

对于分类器,如随机森林^[25,26](random forest, RF)、支持向量机^[27,28](support vector machine, SVM)以及经典的多层感知器^[29](multi-layer perceptron, MLP),在脑电图分类中已得到广泛使用。Bhattacharyya 等人在他们的自动癫痫发作检测系统中结合使用了基于可调 Q 小波变换的特征和 LS-SVM 实现癫痫脑电信号分类^[30]。宋玉龙等人采用经验模态分解和极限学习机相结合的方法对癫痫脑电信号进行分类,识别准确率达到 97%以上^[31]。Chen 等人提出了一种基于最小二乘支持向量机的癫痫发作检测方法。使用离散小波变换对数据进行了预处理,并提取了近似熵、谱熵、模糊熵、样本熵、排列熵、香农熵、条件熵和经验条件熵共 8 种不同的熵来训练分类器以区分癫痫发作间期和发作期,最后使用最小二乘支持向量机、线性判别分析、朴素贝叶斯和随机森林分类器进行分类^[32]。传统的机器学习模型主要依据脑电信号人为挑选、设计出有效的特征,该阶段还要求研究人员具备一定的癫痫脑电信号相关知识。基于机器学习的自动癫痫发作检测技术虽然显示出良好的准确性,但癫痫脑电信号的检测仍是一项艰巨的任务。以波恩大学癫痫数据集为例,大多算法在二分类任务中(如癫痫发作与非癫痫病例)能够准确分类,但在其他分类任务中(如最难区分的癫痫发作间期和发作期)表现不好。

近些年来随着机器学习和深度学习算法的不断发展，机器学习与深度学习算法既可作为开发临床应用的计算机辅助诊断工具，又能探索疾病的病理生理相关机制，并且深度学习作为另一类的机器学习方法，能够自动编码层次结构并适应数据的内部结构，从而提取出不易观察的深层次特征。因此深度学习方法应用于脑电信号分析成为了一种新兴趋势，包括癫痫诊断和癫痫发作检测。Thara 等人摆脱了传统机器学习中至关重要的独立特征提取步骤，直接将原始 EEG 信号输入双向长短期记忆网络中以检测癫痫发作^[33]。Acharya 等人使用 CNN 对原始 EEG 信号进行癫痫检测^[34]。相比之下，Truong 等人通过短时傅立叶变换获得二维特征，输入到 CNN 中进行分类，同时利用了传统的特征提取方法和深度学习^[35]。Zhang 等人使用共空间模式作为低维特征，通过浅层 CNN 进行分类^[36]。Ullah 等人提出了一种用于癫痫自动检测的深度度量学习模型，采用多数投票策略来融合局部用于检测癫痫的决策，在德国波恩大学数据集发作间期(Set D) vs 发作期(Set E)分类上其准确度达到了 97.4%^[37]。

1.3 研究内容与结构安排

本文针对癫痫脑电信号自动分类问题，主要从两个方面展开研究：首先从机器学习角度出发，针对癫痫脑电特征提取和分类两个方面，构建了时频+非线性动力学融合特征和多层感知器的分类模型；然后在深度学习角度建立了基于注意力机制的时间卷积网络模型，并将此深度学习模型用于癫痫脑电信号分类。本文的内容结构如下：

第 1 章首先对本课题的当前研究背景与实际意义做出了简明阐述，然后对当前国内外针对癫痫信号的研究进行了分析，并简要说明了目前脑电信号分类方法存在的一些问题。

第 2 章首先介绍了脑电信号的基础知识，并详细描述了脑电信号的基本特征，然后从时域、频域、时频域和非线性动力学四个方面研究了现存的特征提取方法，之后分别介绍了传统的机器学习分类器和当前应用较为广泛的深度学习模型。

第 3 章构建了一种多域联合分析的癫痫分类方法。首先介绍了多域联合分析方法，包括双谱分析、连续小波变换和特征选择方法，然后介绍了实验中使用的分类器。最后在波恩大学癫痫数据集上对该方法进行验证。从多角度对分类结果进行了具体分析，同时将该方法与使用相同数据集的方法进行对比，最后结合相关研究和实验结果对该章进行了讨论及总结。

第 4 章实现了一种注意力时间卷积网络的癫痫分类方法。该章主要针对机器学习方法和 CNN 网络的弊端进行了优化。首先从卷积模块、注意力模块和时间卷积网络模块三个方面详细介绍了该网络模型，然后使用注意力时间卷积网络模型对脑电信号进行分类，在波恩大学癫痫数据集上对模型进行了训练与测试。最后对所有分类结果进行了总结与分析，并将分类结果与其他方法进行了对比分析。

在结论中总结了本文对于解决癫痫分类问题所做出的工作，指出了目前方法所存在的不足之处，并提出了改进的方向。

第 2 章 脑电信号及癫痫检测方法

2.1 脑电信号及特征

脑电图(electroencephalography, EEG)是一种记录大脑神经电生理活动的方法,它是大脑皮层许多神经元突触后电位的总和,一般直接将电极置于头皮表面进行采集。EEG 的频率范围通常在 0.5 Hz 到 100 Hz 之间,包含了大量的生理特征,包括个体认知能力、性别、年龄、疾病、情绪等信息。不同的个体在大脑的不同功能区之间具有独特的连通性,不同个体在执行相同任务时 EEG 存在差异,但同一个体执行相同任务时脑电信号相对稳定。因此,EEG 具有独特和稳定的特征。并且 EEG 高度依赖于个体的神经活动,具有非常复杂和独特的非线性神经网络结构。因此,通过比较分析 EEG,临床医生可以诊断与神经系统相关的一些疾病^[12, 38]。

表 2-1 脑电信号的不同频段特征

波段	频率范围	振幅范围	状态特点及出现时间
Delta	0.5~4 Hz	10~20 μ V	多数出现在人脑的颞叶和枕叶中,成年人在清醒状态下很少出现 δ 波,常在人体在睡眠、昏迷、深度麻醉等状态下出现
Theta	4~8 Hz	20~40 μ V	主要分布在额叶和中央区, θ 波是正常儿童脑电图的主要成分,成年人情绪低沉、感情压抑时出现
Alpha	8~13 Hz	10~100 μ V	大脑各部分都有 α 波, α 波是正常脑电的基本节律人在清醒或安静闭眼时等状态下出现,震荡的幅度大并且数目最多
Beta	13~30 Hz	5~30 μ V	主要分布于额、中央区,正常成年人在精神紧张及情绪激动的情况下易产生此波,标志着大脑处于兴奋状态
Gamma	30 Hz 以上	< 2 μ V	主要分布于前中央及额区,与人的清醒机制有关,是一种频率较高,振幅较低的波

EEG 在不同神经状态下具有不同的频率。研究人员正试图找到最适合分析的频段,以减少用于分析的数据量。人在不同的生理或心理状态下会表现出不同的脑电频率,在一定频率范围内的节律性活动代表着特定的脑活动状态,因此,需要对脑电的

不同频段进行有针对性的研究，表 2-1 中列出了不同频段的特征。

目前临床上获取 EEG 的方式主要有两种：侵入式和非侵入式。脑电图是最常用的非侵入式技术，它直接测量靠近皮层表面的神经元树突的电势。脑电信号的时间分辨率远好于空间分辨率。它的优点是成本低，不会对人体造成损害，但是容易受到肌电，眼电等伪迹的影响，所采集到的脑电信号，比较微弱，信号的信噪比较低^[39]。临床诊断时 EEG 采集装置通常采用国际标准 10/20 脑电记录系统^[40]，电极放置位置如图 2-1 所示。图中 A_i 表示耳垂， C_i 表示中央区， P_{gi} 表示鼻咽， P_i 表示顶叶， F_i 表示额叶， F_p 表示额极， O_i 表示枕区。该标准由美国脑电图学会定制。

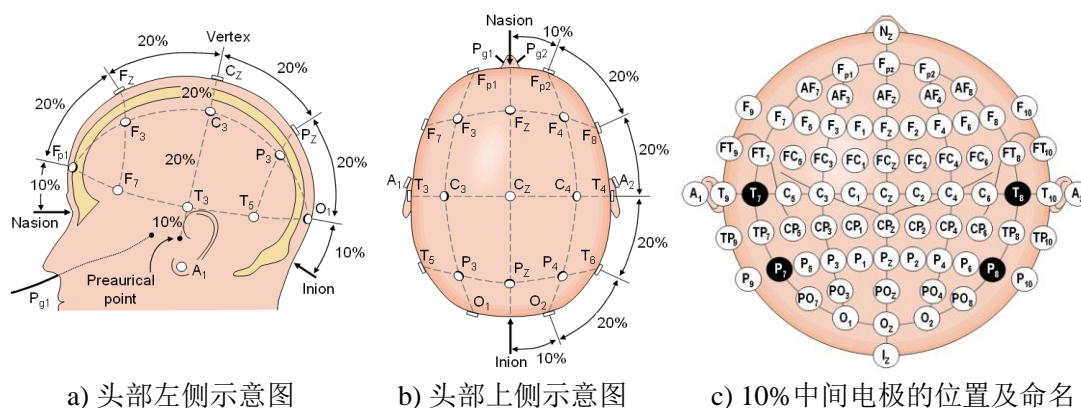


图 2-1 国际标准 10/20 脑电记录系统^[40]

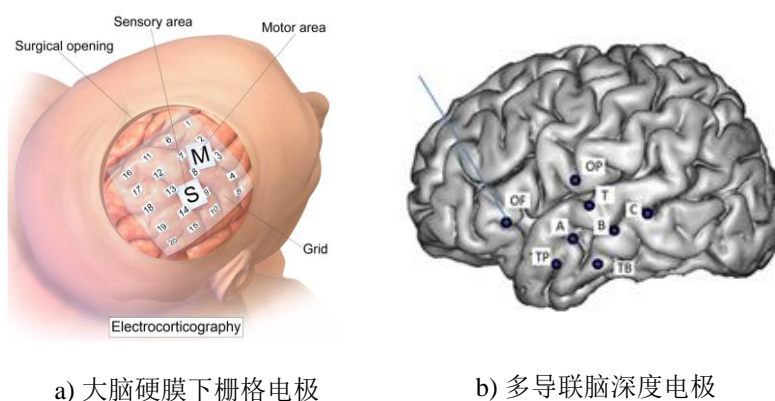


图 2-2 颅内脑电信号的采集方式^[41]

相对于非侵入式的头皮脑电图技术，侵入式的颅内脑电图技术是通过有创的方式以颅内电极记录 EEG，一般称为颅内脑电信号(intracranial electroencephalography, iEEG)。其中包括皮层脑电图(electrocorticography, ECoG)和立体定向脑电图

(stereotactic electroencephalography, SEEG)。ECoG 和 SEEG 可以提供高精度空间和时间分辨率的数据。在局灶性癫痫患者切除手术前可以使用 iEEG 进行癫痫病灶定位。ECoG 通过开颅手术将电极栅格放置在硬膜下间隙, 根据临床需要, 它们通常放置在皮质的特定区域上。但是 ECoG 只能记录皮质表面的电活动, 无法记录更深层次的海马体等结构。SEEG 可以通过颅骨植入穿透电极以测量大脑更深层结构中的电活动^[42]。与头皮脑电相比, SEEG 能提供更高空间分辨率的局部化信息^[43]。图 2-2 展示了颅内脑电信号的采集方式: ECoG 和 SEEG 分别使用大脑硬膜下栅格电极和多导联脑深度电极获取颅内脑电信号^[41]。

2.2 癫痫脑电信号的特征提取方法

在机器学习中, 特征提取是最重要的一环。特征提取是一个从脑电信号中提取出最具区分性和非冗余性信息的过程。它降低了数据的维度, 利用特征可以提高分类器的判别性能。从单个通道提取的特征称为单变量特征, 从多个通道提取的特征称为多变量特征。在脑电信号分析中主要的分析方法有: 时域、频域、时频域和非线性动力学四大类, 另外还有基于深度学习模型的方法。

时域分析方法是从信号的时域中提取有效信息, 以减少噪声便于进一步处理。脑电信号是一种时域波形, 包含了时间维度的所有特征, 它随时间变化, 显示出信号的非平稳性。时域分析方法可以直接对波形信息进行分析, 常采用均值、中值、方差、归一化等统计方法和信号平滑技术从信号中提取必要的信息以此获得较高的信噪比。

大脑神经元产生的信号具有高度非平稳性, 且广泛分布于各个频率段上, 频域分析方法就是根据大脑信号处于不同的频率段或者根据信号在某一频率段的特征, 从中提取信息, 获得信号之间的差异。脑电信号的频域分析主要采用滤波器和频谱估计等分析方法。在癫痫发作期间, EEG 信号的频率会突然发生变化, 这可以通过频域方法来测量。频域特征包括谱质心、变分系数、功率谱密度、信号能量、谱矩和谱偏度提供有关数据变化的有用信息。功率谱估计是一种常用的描述脑电信号在频域随机特性的分析方法, 它使用傅里叶变换将 EEG 信号转换为频率分布。该方法是切比雪夫滤波器、巴特沃斯滤波器、AR 参数模型估计等其他频域分析方法的基础。通过切比雪夫滤波器对脑电信号进行低通滤波, 可以获得特定频段的脑电信号^[44, 45]。

时频域分析法结合脑电信号的时域和频域信息进行分析。同时, 它将一维时间维

度和频率维度的信号转化为二维形式。这种方法有几个优点：首先，相比于时域分析方法它可以提供信号在时间和频率上的详细信息。此外，它还可以提取单个域中不能同时表达的特征，例如信号的瞬态特性和频率变化。时频分析方法包括小波变换(wavelet transform, WT)和希尔伯特-黄变换(hilbert-huang transform, HHT)。小波变换主要对非平稳信号进行时间-频率分析。在小波变换中，对脑电信号进行伸缩和平移，得到小波系数。母小波的选择是小波变换的一个重要步骤。Haar, Daubechies, Symlet是一些常见的小波基函数。小波变换分为离散小波变换(discrete wavelet transform, DWT)、连续小波变换(continuous wavelet transform, CWT)和小波包分解(wavelet packet decomposition, WPD)。HHT 结合了经验模式分解(empirical mode decomposition, EMD)和希尔伯特变换。EMD 将脑电信号分解为本征模态函数(intrinsic mode functions, IMF)，然后对每个 IMF 进行希尔伯特变换，以获得信号相对于时间的瞬时频率和幅度。最后根据局部特征计算加权频率，以区分癫痫发作和非发作事件。

非线性动力学方法结合混沌与分形理论等非线性动力学原理和方法，常用于分析大脑的功能活动状态。现代生理学研究认为大脑是一个混沌动力系统，振幅随时间呈现随机变化。脑电信号包含了数千个神经元活动的信息。此外，神经元的互连和放电行为是非线性的。因此，可以认为产生 EEG 信号的底层神经子系统是非线性的^[46]。近年来，随着对不同脑区之间相关性和神经元放电连通性的研究，相继提出了相位同步、脑网络等非线性方法。研究人员逐渐关注非线性特征，例如放电过程以及参与神经活动的大脑神经元的协调和异步程度。

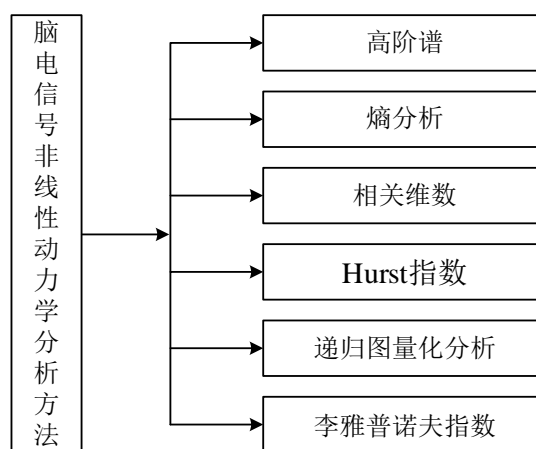


图 2-3 用于癫痫检测的非线性动力学方法

非线性动力学方法还可用于检测信号频谱中谐波之间的耦合。已经提出许多方法,例如相关维数通常用于 EEG 时间序列数据,测量不同事件的复杂性。分形维数旨在比较 EEG 模式中的节律并揭示信号的自相似性。近似熵作为信号不规则行为的指标,可用于测量 EEG 模式的可重复性^[47]。熵衡量了信号中的不确定性,其值表明了不确定性的程度。熵广泛应用于癫痫的诊断中。高熵值意味着不规则性的增加,低熵值意味着混乱程度减少。基于熵的参数有两种类型,称为谱熵和嵌入熵。谱熵是从信号的幅度分量计算的,它描述了 EEG 数据的随机性,而嵌入熵是从时间序列计算的。小波熵也决定了 EEG 数据的混乱程度。利用脑电信号检测癫痫的非线性方法如图 2-3 所示。

2.3 机器学习分类方法

机器学习任务大致可以分为有监督学习和无监督学习,如图 2-4 a)和图 2-4 b)所示。在有监督学习任务中,算法在一组先前已标记的输入数据上进行“训练”,以生成一个预测模型,该模型可以对未标记数据进行预测。相比之下,在无监督学习中,使用算法来发现未标记输入数据中的趋势、子组或异常值。与前面的例子相比,无监督算法可以通过检测脑电记录中的异常值来识别候选癫痫样放电。无论采用哪种方法,都需要通过特征选择的过程来识别信息输入特征,然后使用分类器对这些特征进行分析,从而输出预测。

传统的分类器如随机森林分类器图 2-4 c),它是一种集成学习的方法,主要用于解决分类和回归问题。集成学习作为一种机器学习方案,通过集成多个模型解决同一问题来提高精度。与单个分类器相比,多个分类器参与的集成分类减小了方差,尤其是在分类器不稳定的情况下,可以获得更准确的结果。随机森林最早由 Breiman 提出。该算法的主要思想是在随机抽取的样本中,采用 Bagging 策略,根据随机选取的特征建立多棵分类树,然后利用这些树投票选出一个给定的输入向量,从而得到一个分类标签。随机森林由多个基本学习器构成,每个基本学习器是一棵采用递归划分的独立二叉树。为了构建二叉树,首先从训练数据中提取 N 个对象的引导样本(训练数据中剩余的对象称为 Out-bag,然后递归地选择特征子集并将每个端节点分割为具有最佳选择特征的两个子节点来对树进行拟合,最后通过计算 Gini 指数来决定哪种特征是最好的。

在 k 近邻分类器图 2-4 d)中,给定特征空间中的一个向量表示,并计算输入向量

和训练集中的标记向量之间的距离;最后,将输入分配给其 k 个最邻近的类(例如 $k=5$,输入分配给与其最近的五个训练数据点相同的类)。支持向量机分类器图 2-4 e)与之相反,通过内积函数的非线性变换,在更高维特征空间中生成一个超平面,最大限度地分离标记的训练数据的簇,为分类新的输入提供决策边界。支持向量机分类器的应用有两种方式:一是使用线性边界将数据分类为两类;二是使用更复杂的非线性边界,并根据变换后的特征空间向高阶空间分配类标签。

多层人工神经网络图 2-4 f)则通过节点层来处理数据,其中对每个节点的输入加权求和,并通过非线性激活函数产生中间输出。对于较小的数据集或过于复杂的模型时,分类器可能会对训练数据产生“过拟合”现象。因此,为了限制过拟合,将训练数据分为训练集和验证集,算法从训练集中设置其参数,从验证集中获得算法泛化能力的初步估计。图 2-4 g)为交叉验证法的示意图,该方法保留了训练数据的子集作为验证集(淡蓝色),允许对在训练集(淡黄色)上参数化的算法进行微调;在多次迭代(这里示出 $K=5$ 的 K 折交叉验证)之后,可以在初始保留的测试集(橙色)上测试该算法以评估最终模型的准确性。

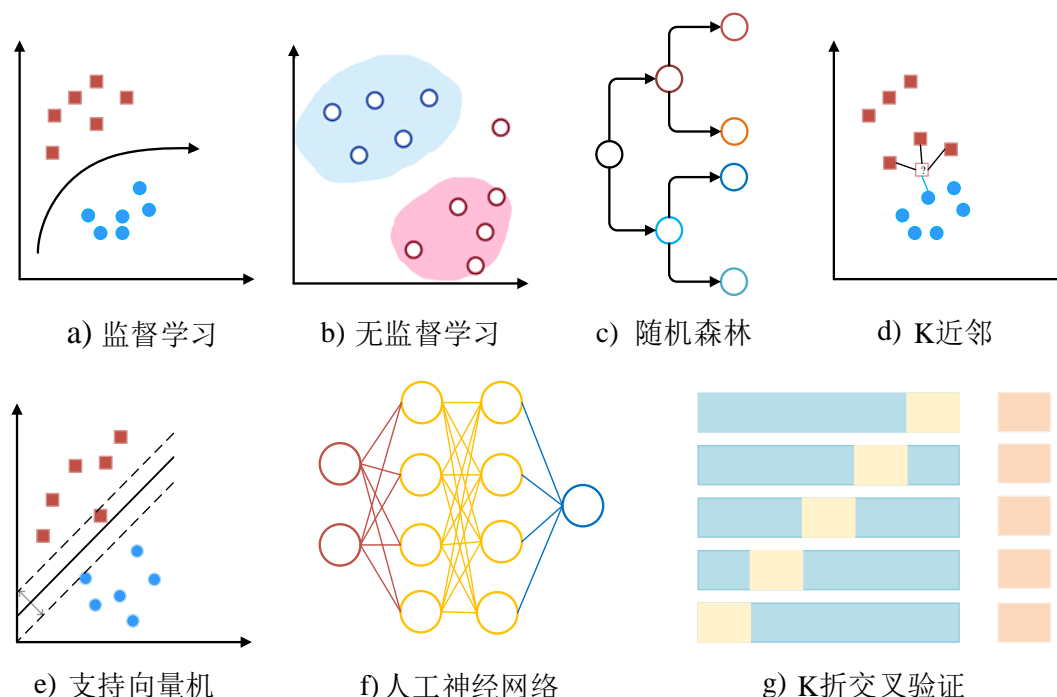


图 2-4 常用的机器学习算法

2.4 深度学习分类方法

癫痫脑电自动分类算法分为自适应分类器、矩阵和张量分类器、迁移学习和深度

学习^[48]。自适应分类器可以根据输入数据的变化重新估计和调整参数。因此可以有效跟踪 EEG 等非平稳信号的特征分布变化。自适应分类器采用三种类型的自适应：有监督、无监督和半监督。迁移学习通过利用在学习一个给定任务时得的知识来处理违反这个假设的数据。换句话说，迁移学习是一组方法论，根据在学习一项任务时获得的信息来提高在另一项任务(也表示为域)上训练的学习分类器的性能。该方法的有效性在很大程度上取决于这两项任务之间的关系。迁移学习非常重要，尤其是在一个给定任务(表示为源域)存在大量标记数据，而第二个任务(表示为目标域)的数据稀缺或获取成本高的情况下。矩阵和张量分类器和基于深度学习的分类器将特征提取、选择和分类合并到一个步骤中，从而提供低信噪比。

卷积神经网络(convolutional neural network, CNN)是一种前馈神经网络(信息从输入层流向隐藏层再流向输出层)。它是深度学习中最常用的神经网络之一，最初用于图像处理领域，后来演变出一维和二维结构，用于生物信号诊断和疾病预测。这类网络广泛应用于脑电信号癫痫发作检测中。在二维卷积神经网络(2D-CNN)中，首先利用频谱图、高阶双谱图和小波变换等可视化方法将一维脑电信号转换成二维图像，然后将其应用于卷积网络的输入。在一维结构中，脑电信号以一维形式作为卷积网络的输入。在这些网络中，对 2D-CNN 的核心架构进行了更改，使其能够处理 1D-EEG 信号。因此，由于二维和一维卷积神经网络(1D-CNN)都被用于癫痫发作检测领域，因此分别对它们进行了研究。图 2-5 显示了用于癫痫发作检测的 2D-CNN 的一般形式。2D-CNN 结构的应用可以说是深度神经网络中最重要的结构。

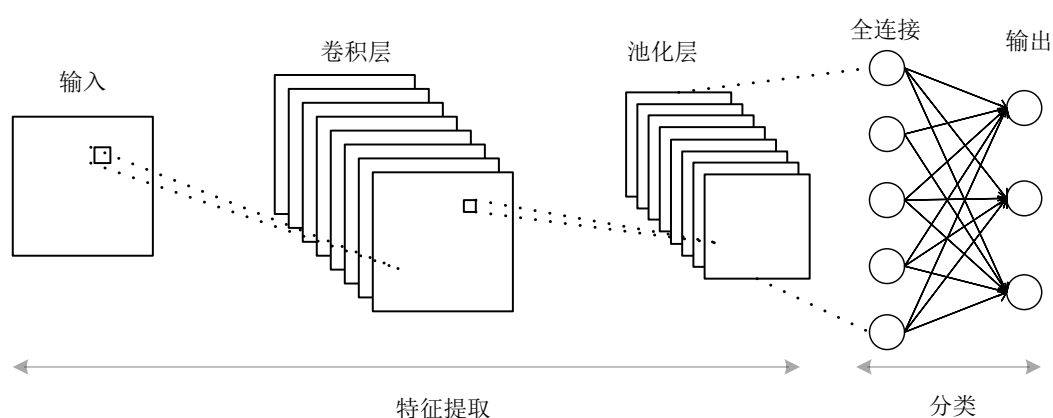


图 2-5 用于癫痫发作检测的典型 2D-CNN

Amin 等人提出了一种新的 2D-CNN 模型，该模型可以提取脑电信号的频谱和时间特征，并利用它们来学习癫痫发作的一般结构^[49]。Zuo 等人从 16 层 2D-CNN 和

EEG 信号中发展出高频振荡癫痫的诊断^[50]。Asif U 等人提出了一个称为 SeizureNet 的深度学习框架，它使用具有密集连接的卷积层^[51]。Covert 等人提出了一种称为时间图卷积网络(temporal graph convolutional network, TGCN)的新型深度学习模型，包括 14、18、22、23 和 26 层的 5 种架构^[52]。Bouaziz 等人将 CHB-MIT 的 23 个通道的脑电信号分割成 2 秒的时间窗口，然后将它们转换成密度图像(空间表示)，作为 CNN 网络的输入^[53]。




图 2-6 典型的 1D-CNN 模型^[54]

1D-CNN 本质上更适合于处理生物信号，如用于癫痫发作检测的脑电。这些结构的形式简单，与 2D-CNN 相比，它参数较少，单次传递速度更快。1D 最重要的优势是可以使用更大尺寸的池化和卷积层。此外，信号本质上是一维的，使用预处理方法将其转换到二维可能会导致信息丢失。图 2-6 显示了用于癫痫发作检测的 1D-CNN 的一般结构。

循环神经网络是以人的记忆特点为基础提出的，也就是说，当该网络对数据进行处理时，在考虑到前一刻输入的情况下还涉及到对上一部分内容的记忆。由于这种特殊的网络结构，循环神经网络在进行视频处理、文本生成等领域取得优秀的成绩。而一般 RNN 的问题是短期记忆。在长序列数据中，由于在不同时间窗口之间传递信息很困难，因此 RNN 可能会忽略一些关键信息。RNN 的另一个缺点是梯度消失问题。该问题是由于反向传播过程中梯度的缩小而产生的。为了解决短期记忆问题，人们创造了长短期记忆网络(long-short term memory, LSTM)的门。通过门来调节信息流。这些门可以保留长序列中必要的信息，并丢弃不需要的数据。

门控循环单元(gated recurrent unit, GRU)是一种基于 LSTM 的门控循环神经网络变体，旨在解决长序列数据处理中的梯度消失和梯度爆炸问题。GRU 通过将输入门

和遗忘门合并为一个更新门,减少了门控信号的数量。该更新门可以同时控制信息的输入和遗忘,同时 GRU 还引入了一个复位门,用于控制历史状态的重置。GRU 通过将输入门和遗忘门合并为一个更新门,减少了门控信号的数量。该更新门可以同时控制信息的输入和遗忘,还可以同时控制二者的比例,从而减轻了模型参数量和计算量的压力。此外,GRU 还引入了一个复位门,用于控制历史状态的重置,从而增强了模型对输入序列的建模能力。相对于 LSTM,GRU 在门控机制上进行了一些修改,既简化了模型结构,又保持了一定的模型性能。Talathi 等人在一次实验中使用了一种基于 GRU 的自动诊断系统来检测癫痫发作^[55]。该方法在预处理过程中,将输入信号分割成时间窗口,并从时间窗口中获得谱图。然后将这些谱图馈送到带有 Softmax 和全连接层的四层 GRU 网络,获得了 98% 的准确率。在另一项研究中,Roy 等人使用了带有 Softmax 分类器的五层 GRU 网络,并取得了显著的效果^[48]。此外,RNN 可以与 CNN 相结合,有效地提取时空域特征。Wilaiprasitporn 等人提出了一种结合 CNN 和 RNN 的深度学习模型,其中 CNN 用于处理脑电信号的空间信息,RNN 用于提取时间信息。同时采用 LSTM 和 GRU,在 DEAP 数据集上实现了不同情感状态的识别,平均准确率为 99.90-100%^[56]。

Transformer 模型于 2018 年提出,是一种基于多头自注意力的神经网络,最初用于自然语言处理任务中^[57]。随着它的发展,因其卓越的效果逐步取代了 RNN。基于 EEG 的 Transformer 模型已被用于情绪识别^[58]、想象语音分类^[59]和睡眠阶段分类^[60]。一些研究试图将 Transformer 模型用于运动想象脑电信号。Tao 等人于 2021 年提出一个门控 Transformer 结构,并将其成功应用于脑视觉领域和 EEG 信号领域。该结构利用门控机制对输入矩阵进行归一化,并在前馈层或自注意力层前加入门控层,以增强学习效果。尽管该模型在脑视觉领域表现良好,但在应用于 EEG 领域时,分类准确率较低。因此,后续的优化工作仍有待进一步研究和探索^[61]。

Transformer 是一种基于注意力机制的神经网络结构,与传统的卷积神经网络和循环神经网络不同,它完全抛弃了卷积和循环结构,仅依赖注意力机制来获取输入和输出之间的相关性。在传统的卷积神经网络中,获取长距离信号之间关联程度的方式是增加卷积层深度。因为每个卷积层的感受野有限,只有增加层数才能获得更全局的信息。而 Transformer 的注意力结构巧妙地避免了此种问题,它能够直接计算每个序列上不同位置的信息,并得出这个序列的综合表示。相较于循环神经网络,注意力机制模型的单个模块计算复杂度低,且多层结构能够同时进行计算,加快了计算效率。

此外,这种端到端的结构也使得模型训练更加方便,可以轻松集成到系统中使用^[61]。

Transformer 结构由编码器—解码器(encoder-decoder)两部分组成,这两部分完全基于注意力机制和全连接。通过堆叠多个层(默认为 6 层)来实现数据的高效编码和解码。在该结构中,数据经过多层编码器后输出到每一层解码器上。编码器每子层都由多头注意力层(multi-head attention)和前馈连接层(feed forward)组成。解码器的每个子层包括遮蔽多头注意力层(masked multi-head attention)、多头注意力层和前馈连接层。每个子模块都包含层归一化(layer normalization)和残差连接(residual Connection)。

2.5 本章小结

本章首先对脑电信号及特征进行了介绍;其次分别从时域、频域、时频域和非线性动力学四个方面详细解释了脑电信号的特征提取方法;接着介绍了传统的机器学习分类器的基本原理;最后详细介绍基于深度学习的脑电信号分类模型。本章为第三、四章实验过程及分析做好铺垫。

第3章 基于多域联合分析的癫痫分类方法

3.1 引言

机器学习作为癫痫分类的策略已经讨论了十多年,但仍然具有挑战性。在机器学习中,癫痫发作检测被认为是一个分类问题,相应的算法遵循一个标准的范式:预处理(去伪迹、滤波和加窗等),特征提取和分类器分类。其中,多数特征提取方法是以脑电信号的频谱分析为基础的。最具代表性的是功率谱分析,它将时域的 EEG 信号转换至频域中,从而直观地看到脑电信号的能量变化。但是该转换会损失脑电信号中的某些病变的瞬时信息,较为片面。时频分析法是一类能够在时域和频域同时对信号进行表征的分析方法,可有效表征脑电信号的瞬态信息,提高癫痫脑电信号自动分类算法的性能。虽然时频分析方法能够获取大脑的非平稳信息,但是它无法捕捉脑电信号分量之间的非线性动态变化。非线性动力学分析法能够有效地描述不同类型脑电信号的动力学特性,但是这种单一的特征提取方法在信息表达方面不够全面,只能反映信号的部分有效信息。因此,需要寻找一种适合癫痫分类的组合特征。针对此问题,本研究构建了一种时频与非线性动力学特征的多域联合分析方法,用于识别正常、癫痫发作间期和癫痫发作时期的脑电信号。该方法通过使用双谱分析和连续小波变换相结合的方式,在信息内容方面,此方法利用多种分析方法的优势对脑电信号进行更加全面的表征,以达到脑电信号多域信息挖掘的目的,从而获得更准确的分析结果和更高效的分类性能。

3.2 实验内容

3.2.1 波恩脑电数据集

本实验使用的是德国波恩大学提供的癫痫脑电数据^[62]。它由 A、B、C、D 和 E 五个数据集组成,每个数据集包含 100 个单通道脑电信号片段,每段信号的持续时间为 23.6s,采样率为 173.61Hz。其中,Set A 和 Set B 为头皮脑电信号,使用国际标准的 10-20 系统在五名健康受试者上进行电极放置。Set C、Set D 和 Set E 的脑电数据来自 5 例接受术前评估的癫痫患者。Set C 和 Set D 为癫痫发作间期的颅内脑电信号,它们分别是患者对侧大脑半球的海马结构和病灶区内的脑电信号。Set E 是在患

者癫痫发作期使用放置在病灶区内的深度电极获取的脑电信号。表 3-1 为脑电信号的说明，图 3-1 为三个数据集的脑电信号示例。

表 3-1 脑电信号说明

受试者	健康受试者			癫痫患者	
数据集	Set A	Set B	Set C	Set D	Set E
状态	睁眼	闭眼	发作间期	发作间期	发作期
电极类型	头皮	头皮	颅内	颅内	颅内
电极放置	10-20	10-20	海马	病灶区	病灶区




图 3-1 三个数据集的脑电信号示例

3.2.2 实验流程

图 3-2 为本实验进行癫痫脑电信号分类的整体流程图，主要分为以下几个部分：

(1)预处理 数据在 0.5~40Hz 的频带内使用带通滤波器进行滤波(使用 EEGLAB 工具箱^[63]中的 'eegfilt' 函数)。

(2)双谱分析 本研究从数据库中选取了三组数据集,分别是正常人睁眼(Set A)、癫痫发作间期(Set D)和癫痫发作期(Set E)。对每个脑电信号进行双谱计算,得到双谱等高线图,如图 3-4 所示,双谱等高线图显示了不同状态下脑电信号频率的非线性耦合现象。

(3)时频分析 对每个脑电信号进行连续小波变换得到时频图。如图 3-5 所示,时频图可以显示不同状态下脑电信号随时间变化的能量分布。

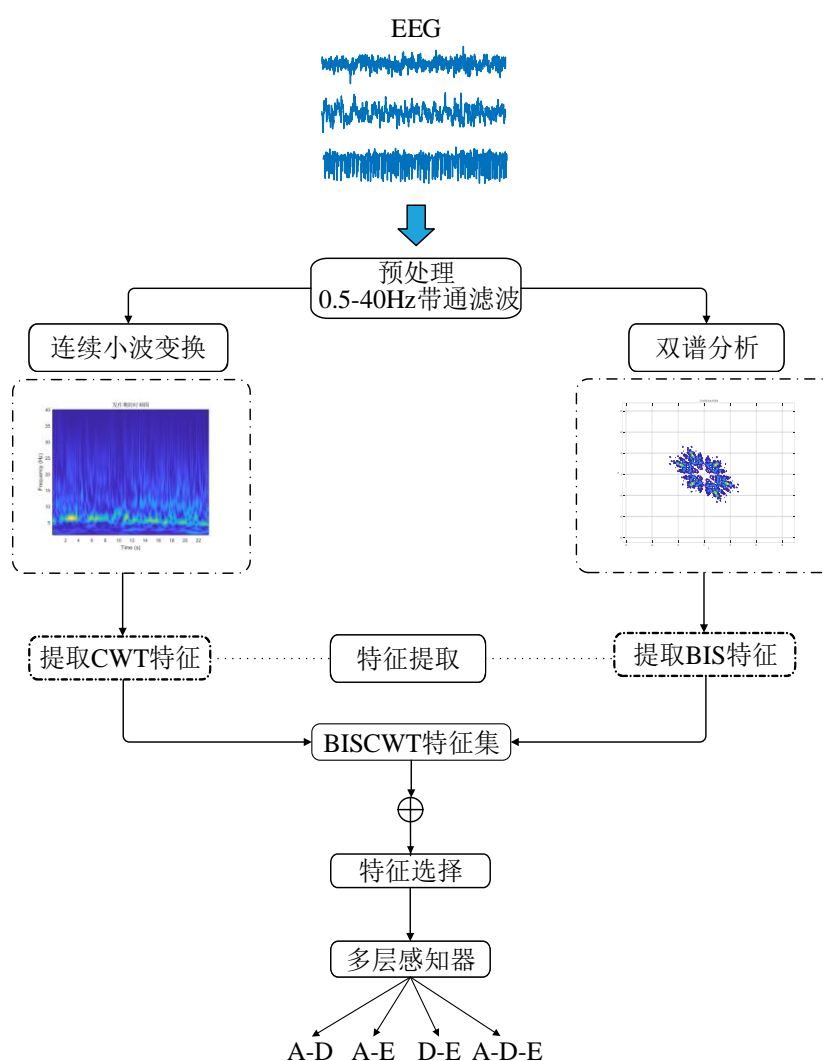


图 3-2 脑电信号分类流程图

(4)特征提取 所有的特征均从双谱图和小波变换时频图中提取。双谱特征(BIS特征) 将双谱图按照五种子频带($\delta[0.5 \sim 4 \text{ Hz}]$ 、 $\theta[4 \sim 8 \text{ Hz}]$ 、 $\alpha_1[8 \sim 10 \text{ Hz}]$ 、 $\alpha_2[10 \sim 13 \text{ Hz}]$ 、 $\beta[13 \sim 30 \text{ Hz}]$)划分为五个区域。接下来,在每个区域计算以下 BIS

特征：归一化双谱熵、归一化双谱平方熵、双谱幅度均值、双谱对数振幅之和、双谱中对角元素的对数振幅之和、双谱中对角元素的一阶谱矩、双谱加权中心，得到 BIS 特征集。连续小波变换特征(CWT 特征) 将时频图按照上面五种子频带划分为五个区域。接下来，在每个区域提取连续小波变换特征：均值、标准差、偏度、峰度和熵，得到 CWT 特征集。将 BIS 和 CWT 特征集进行融合形成 BISCWT 特征集。

(5)特征选择 为了降低数据维度，提高学习的准确性，使用基于树的特征选择方法对提取的特征集进行特征选择，删除一些不必要的和不相关的特征。

(6)结果比较 设计了四种分类任务(A-D、A-E、D-E、A-D-E)，生成三类特征集(BIS 特征集、CWT 特征集和 BISCWT 特征集)，将这三类特征集作为分类器的输入，根据多种评估指标对结果进行比较。

3.3 多域联合分析方法

3.3.1 双谱分析方法及特征

高阶谱(higher order spectrum, HOS)是一种常用的非线性动力学方法。它是随机过程中高阶累积量的谱表示。高阶谱包括三阶及以上累积量。高阶谱提供了从高斯信号中提取信息偏差的能力，并保留了信号的相位信息。因此，高阶谱能够估计非高斯信号的相位。此外，高阶谱还检测和表征信号中的非线性。相比之下，二阶测量是功率谱，只能揭示信号的线性和高斯信息。

列举一个简单的例子，用来说明信号中的非线性和相位信息。

$$x(t) = A_1 \cos(2\pi f_1 t + \varphi_1) + A_2 \cos(2\pi f_2 t + \varphi_2) \quad (3-1)$$

$$h(t) = ax^2(t) \quad (3-2)$$

这是一个在非线性系统中的信号 $x(t)$ ，信号的输出主要包含频率和相位，其成分有： $(2f_1, 2\varphi_1)$ ， $(2f_2, 2\varphi_2)$ ， $(f_1 + f_2, \varphi_1 + \varphi_2)$ ， $(f_1 - f_2, \varphi_1 - \varphi_2)$ 。频率之间需要满足 $f_1 \pm f_2$ ，并且相位之间满足 $\varphi_1 \pm \varphi_2$ 。只有当这两种关系同时满足时才可以叫做二次相位耦合，所以信号中存在二次相位耦合现象可以表明系统是非线性的。

高阶谱具有如下特点：

非高斯线性过程的 HOS 既包含幅度信息，又包含相位信息。它们常用于时间序列建模，以及非最小相位和非因果系统的识别。

高斯信号的 HOS 在统计上为零。因此, HOS 可以用来测量非高斯性, 并分离独立的非高斯信号和高斯噪声的加性混合。可以利用该特征来检测和分类非高斯信号, 并在信号源被高斯噪声破坏的应用中提供高抗噪性。

HOS 能够检测和表征机制的非线性特性, 这些机制通过谐波分量的相位关系生成时间序列。

HOS 是平移不变的, 因为线性相位项在定义它们的傅立叶系数的乘积时被抵消了。它可作为模式识别特征的函数可以从满足其他所需不变性(如缩小、放大和旋转不变性)的高阶谱定义。

高阶谱又称为多谱, 是指包含多个频率的谱。其中三阶谱称为双谱, 反映了两个频率之间的相互作用; 而四阶谱称为三谱, 则表征了三个频率之间的相互作用。在高阶谱分析中, 双谱具有高阶谱的特性, 且其阶次最低, 因此计算量最小, 是高阶谱分析中最简单的一种。一般而言, 双谱常用于表示二阶相互作用的频率谱, 通常用于对信号的非线性特性进行分析。而三谱则通常用于表示三阶相互作用的频率谱, 由于其阶次较高, 计算量相对较大。因此, 习惯上使用双谱进行高阶谱分析。

对于一个均值为 0 的随机变量 $\{x(n)\}$, 它满足 k 阶累计量绝对可和

$$\sum_{m_1=-\infty}^{\infty} \dots \sum_{m_{k-1}=-\infty}^{\infty} |c_{k,x}(m_1, m_2, \dots, m_{k-1})| \quad (3-3)$$

其中 m 表示随机过程 $\{x(n)\}$ 的 k 阶矩, c 为随机过程的累积量。

则 $\{x(n)\}$ 的 k 阶谱为 k 阶累积量的 $k-1$ 维傅里叶变换,

$$S_{k,x}(\omega_1, \omega_2, \dots, \omega_{k-1}) = \sum_{m_1=-\infty}^{\infty} \dots \sum_{m_{k-1}=-\infty}^{\infty} |c_{k,x}(m_1, m_2, \dots, m_{k-1})| e^{-j(\sum_{i=1}^{k-1} \omega_i m_i)} \quad (3-4)$$

其中 $S_{k,x}$ 表示高阶累积量谱, 当 $k=3$ 时:

$$S_{3,x}(\omega_1, \omega_2) = \sum_{m_1=-\infty}^{\infty} \dots \sum_{m_{k-1}=-\infty}^{\infty} |c_{3,x}(m_1, m_2)| e^{-j(\omega_1 m_1 + \omega_2 m_2)} \quad (3-5)$$

即, 三阶累积量的二维傅里叶变换, 称之为双谱。双谱一般可以表示为:

$$B(f_1, f_2) = E\{X(f_1)X(f_2)X^*(f_1 + f_2)\} \quad (3-6)$$

其中 $X(f)$ 是信号 $X(t)$ 的傅里叶变换, $B(f_1, f_2)$ 为双谱计算值。 $X(f)$ 可以通过下式计算得到:

$$X(f) = \sum_{t=-\infty}^{\infty} x(t)e^{-2j\pi ft} \quad (3-7)$$

双谱计算得到一个复数值，以幅值和相位的形式表示，如下：

$$B(f_1, f_2) = |B(f_1, f_2)| e^{j\varphi(f_1, f_2)} \quad (3-8)$$

其中相位关系满足：

$$\varphi(f_1, f_2) = \varphi(f_1) + \varphi(f_2) - \varphi(f_1 + f_2) \quad (3-9)$$

双谱的归一化形式如下：

$$b^2(f_1, f_2) = \frac{|B(f_1, f_2)|^2}{E\{|X(f_1)X(f_2)|^2\}E\{|X(f_1 + f_2)|^2\}} \quad (3-10)$$

双相干是双谱的另一种形式，它也可以描述二次相位耦合现象，其特点是双相干值分布在 0 和 1 之间，如果 $f_1 + f_2$ 的分量全部来自 f_1 和 f_2 ，并且 $\varphi_1 + \varphi_2$ 的分量也全部来自 φ_1 和 φ_2 ，则双相干的结果为 1，如果不满足这种二次相位耦合的关系，则双相干的结果为 0，所以这种归一化的幅值，同样具有检测非线性的作用。

双谱作为高阶谱分析中最简单、最有应用价值的一种方法，它具有以下特性：

双谱一般为复数，即

$$B(f_1, f_2) = |B(f_1, f_2)| e^{j\varphi(f_1, f_2)} \quad (3-11)$$

式中 $|B(f_1, f_2)|$ 和 $\varphi(f_1, f_2)$ 分别表示双谱的幅值和相位。

双谱是周期函数，两个周期均为 2π ，即

$$B(f_1, f_2) = B(f_1 + 2\pi, f_2 + 2\pi) \quad (3-12)$$

$B_x(f_1, f_2)$ 具有对称性：

$$\begin{aligned} B(f_1, f_2) &= B(f_2, f_1) = \\ &B^*(-f_1, -f_2) = B^*(-f_2, -f_1) = \\ &B(-f_1 - f_2, f_1) = B(-f_1 - f_2, f_2) = \\ &B(f_1, -f_1 - f_2) = B(f_2, -f_1 - f_2) \end{aligned} \quad (3-13)$$

对于零均值高斯信号，双谱为 0。

双谱估计有直接法和间接法两种计算方法。直接法的计算量相对较小，因此本章使用非参数直接法来计算脑电信号的双谱：

将数据分为 K 段，每段 M 个采样点 ($N = M \times K$)；

对每段数据进行离散傅里叶变换，得到 DFT 系数；

计算三重相关系数，得到每段数据的双谱；

$$b(f_1, f_2) = X(f_1)X(f_2)X^*(f_1, f_2) \quad (3-14)$$

将 K 段的双谱估计取平均值。

$$B(f_1, f_2) = \frac{1}{K} \sum_{i=1}^K b_i(f_1, f_2) \quad (3-15)$$

双谱是一个在频率平面 (f_1, f_2) 上具有二维表示的复数，并且它具有对称性，如图 3-3 所示，展示了双谱的对称区和非冗余区。因此，在给定采样频率 f_s 的情况下，其在非冗余区域 (Ω) 中的计算 (定义在边界 $0 \leq f_2 \leq f_1$ 和 $f_1 + f_2 \leq 0.5f_s$) 可以完整地描述信号的双谱特性。




图 3-3 双谱的对称区和非冗余区

从双谱的非冗余区域 (Ω) 按照五种脑电节律 (δ [0.5~4Hz]、 θ [4~8Hz]、 α_1 [8~10 Hz]、 α_2 [10~13Hz]、 β [13~30Hz]) 划分得到五个频段，并在每个频段中按照以下公式计算双谱特征。

归一化双谱熵

$$BE_1 = -\sum_n P_n \log P_n \quad P_n = \frac{|B(f_1, f_2)|}{\sum_{\Omega} |B(f_1, f_2)|} \quad (3-16)$$

归一化双谱平方熵

$$BE_2 = -\sum_n Q_n \log Q_n \quad Q_n = \frac{|B(f_1, f_2)|^2}{\sum_{\Omega} |B(f_1, f_2)|^2} \quad (3-17)$$

双谱幅度均值

$$M_{ave} = \frac{1}{L} \sum_{\Omega} |B(f_1, f_2)| \quad (3-18)$$

双谱对数振幅之和

$$H_1 = \sum_{\Omega} \log(|B(f_1, f_2)|) \quad (3-19)$$

双谱中对角元素的对数振幅之和

$$H_2 = \sum_{\Omega} \log(|B(f_d, f_d)|) \quad (3-20)$$

其中 $B(f_d, f_d)$ 表示对角线元素 (f_d, f_d) 处的双谱值, d 是子带内分析的对角元素数。

谱中对角元素的一阶谱矩

$$H_3 = \sum_{\Omega} k \log(|B(f_d, f_d)|) \quad (3-21)$$

双谱加权中心

$$WCB_x = \frac{\sum_{\Omega} f_1 B(f_1, f_2)}{\sum_{\Omega} B(f_1, f_2)} \quad (3-22)$$

$$WCB_y = \frac{\sum_{\Omega} f_2 B(f_1, f_2)}{\sum_{\Omega} B(f_1, f_2)} \quad (3-23)$$

$$aWCB_x = \frac{\sum_{\Omega} f_1 |B(f_1, f_2)|}{\sum_{\Omega} |B(f_1, f_2)|} \quad (3-24)$$

$$aWCB_y = \frac{\sum_{\Omega} f_2 |B(f_1, f_2)|}{\sum_{\Omega} |B(f_1, f_2)|} \quad (3-25)$$

式中 n —— 表示子带内分析的点数;

L —— 表示非冗余区的点数。

正常对照组、癫痫发作间期和癫痫发作期脑电信号双谱估计如图 3-4 所示, 包括二维等高线图, 双谱的非冗余区的三维图和双谱非冗余区的对角切片图。蓝色和红色分别表示双谱幅值的相对变化, 幅值越大, 表明频率之间的二次相位耦合越强。将正常对照组和患者癫痫发作间期组双谱对角切片图进行对比, 可以看出相位耦合谐波从较高频率转移到较低频率。癫痫患者发作间期时双谱在 δ 频段的 1.8 Hz 出现主峰, 癫痫患者发作期时双谱在 δ 频段的 3.3 Hz 出现主峰, 而正常对照组在 δ 、 θ 和 α 频段 ([0.5-4 Hz]、[4-8 Hz]、[8-13 Hz]) 均出现尖峰值。与正常脑电信号相比, 癫痫发作过程中低频的耦合强度增加。在所示数据样本中, 不同脑电信号的双谱存在显著差异。显然双谱为这三种类型的脑电信号提供了独特的特征。

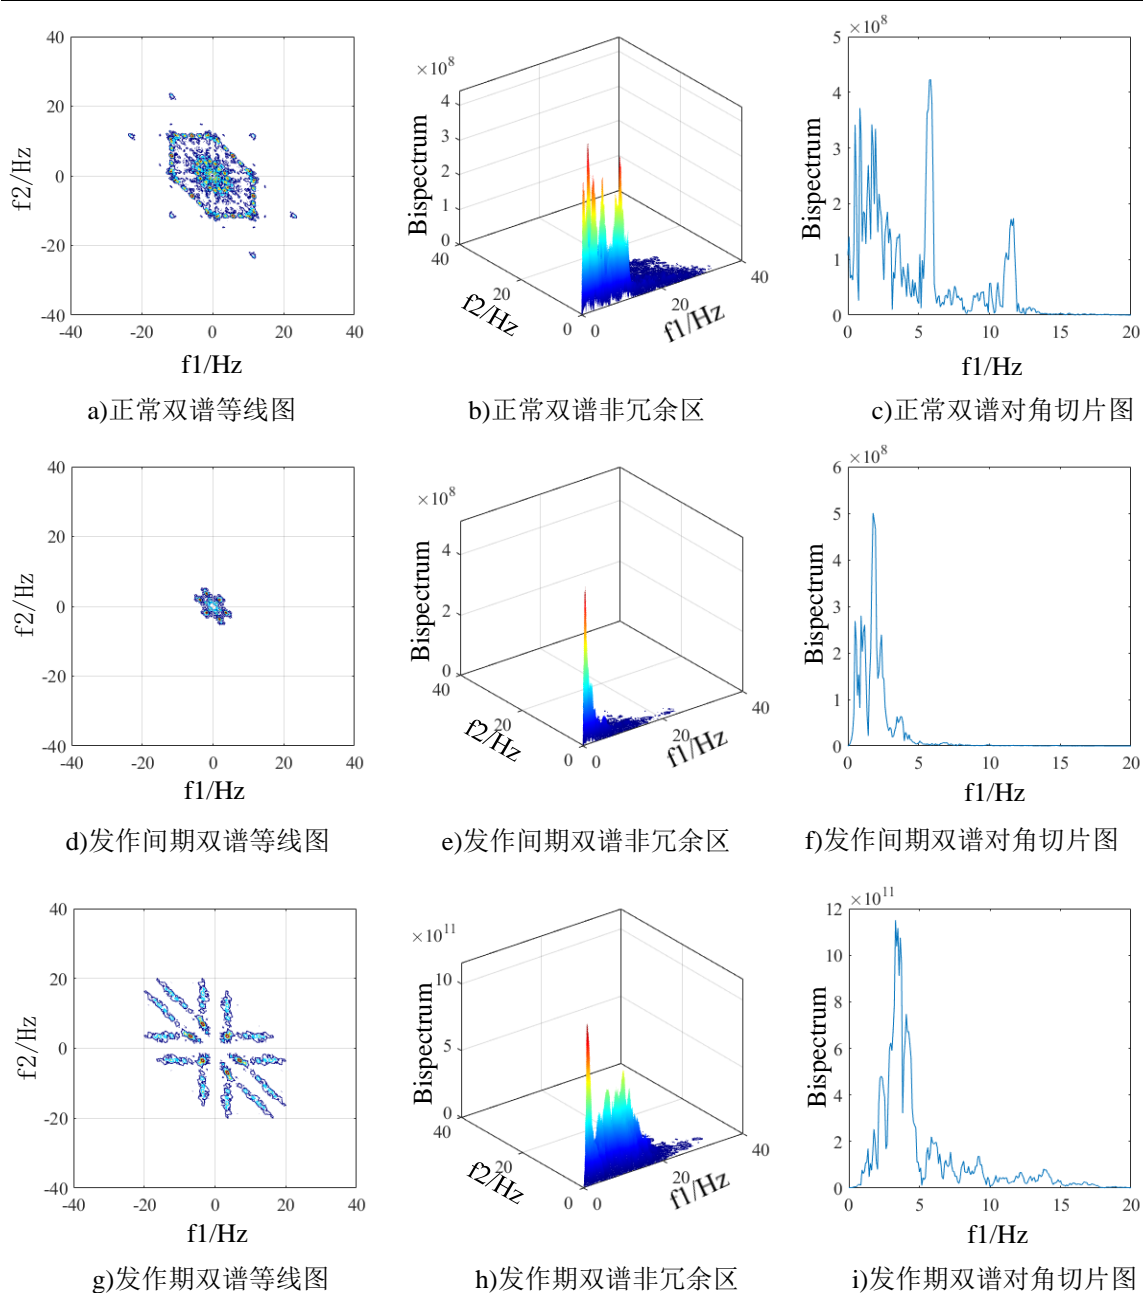


图 3-4 三类脑电信号的双谱等线图、非冗余区三维图和双谱对角切片图

3.3.2 连续小波变换及特征

随着信号处理技术的快速发展，小波分析已经成为一种广泛应用于非平稳信号处理的重要技术。小波分析最初由 Morlet 提出，在处理非平稳信号时有着独特的优势。与傅里叶变换不同，小波分析通过使用多尺度分析方法，根据需要使用不同的窗口宽度进行变换。它能够在较大窗口下分析低频信号，在较小窗口下来分析较高频信

号。这种方法可以为不同频率的信号提供更好的分辨率，同时也能保持良好的时间分辨率。具体而言，较低频率的信号可以获得更好的频率分辨率，但时间分辨率较差；而较高频率的信号时间分辨率好但频率分辨率较差。因此，小波分析是一种非常适合分析非平稳窄带信号的方法。

对于一个连续可积的信号 $s(t)$ ，其连续小波变换可以定义为：

$$CWT(a,b) = \frac{1}{\sqrt{a}} \int s(t) \bar{\psi}\left(\frac{t-b}{a}\right) dt \quad (3-26)$$

式中 a —— 表示尺度变量；

b —— 表示时移因子；

$\psi(t)$ —— 表示母小波函数；

$CWT(a,b)$ —— 表示小波变换的系数。

小波变换是一种在时域和频域之间转换的信号处理方法，其在实际应用中广泛使用。然而，随着时域和频域支撑的限制，需要在小波基函数的选择中权衡各种要求。具体而言，需要选择一种小波基函数，以满足两个主要要求：首先，由母小波形成的小波基函数应该是两两正交的；其次，母小波应该具有高阶消失矩。此外，由于时域和频域的限制，需要在时域和频域之间进行取舍。

尽管存在多种小波基函数可供选择，例如：*Haar*、*Daubechies*、*Morse*、*Symlet*、*Coifet* 等。但目前尚未有理论标准来确定哪种小波基函数最适合特定应用。因此，在选择小波基函数时，需要考虑多种因素。可以通过小波变换后的小波系数选择小波基函数，系数越大，对应的小波函数越接近分析信号的波形，反之系数越小，二者之间的相似性就越小。另外还可以根据分析的需求来选择小波基函数。例如，如果需要分析信号的近似特征，可以选用尺度较大的小波，如果想得到信号的细节，就选用尺度小的，但是目前小波基函数的种类较多，在实际应用的过程中，大都根据实际经验选用小波基函数。

本章采用 *Morse* 小波作为小波分析基函数的，广义莫尔斯小波是一个完全解析的小波系列。解析小波是复值小波，其傅里叶变换只支持正实轴。它们对分析调制信号很有效，这些信号的振幅和频率是随时间变化的。因此它们也可以有效分析局部不连续的序列。

对每个脑电信号进行连续小波变换，在时频图中同样划分为五个频段，从中分别提取以下特征(CWT 特征)：均值、标准差、偏度、峰度和香农熵。图 3-5 显示了从正

常、发作间期和发作期脑电信号中计算的时间频图。




图 3-5 三类脑电信号的时间频图

从时域角度分频带提取的特征包括平均值、标准差、峰度、偏度和香农熵。其中平均值公式如下：

$$Avg = \frac{1}{m} \sum_{i=1}^m CWT_i \quad (3-27)$$

标准差代表了整个数据的稳定程度，其公式为：

$$Std = \sqrt{\frac{1}{m} \sum_{i=1}^m (CWT_i - Avg)^2} \quad (3-28)$$

峰度(kurtosis)，又称峰态系数，是一种用于描述概率密度分布曲线在其均值处峰值高低的指标。直观地说，峰度度量了峰值的尖锐程度，以反映概率密度函数的形态特征。该指标的计算是相对于正态分布而言的，若峰度大于 0，则表明该分布的峰形态比正

态分布更尖峭，具有更加突出的峰值。

$$Kurtosis = \frac{\frac{1}{m} \sum_{i=1}^m (CWT_i - Avg)^4}{(\frac{1}{m} \sum_{i=1}^m (CWT_i - Avg)^2)^2} \quad (3-29)$$

偏度表示所有采样点的不对称度，其公式为：

$$Skewnes = \frac{\frac{1}{m} \sum_{i=1}^m (CWT_i - Avg)^3}{(\frac{1}{m} \sum_{i=1}^m (CWT_i - Avg)^2)^{\frac{3}{2}}} \quad (3-30)$$

香农熵用于衡量脑电信号的混沌程度，其公式为：

$$H(CWT) = -\sum_{i=1}^m p(CWT_i) \log_2 p(CWT_i) \quad (3-31)$$

式中 m —— 表示总数；
 CWT_i —— 表示时频值；
 Avg —— 表示总体数据的平均值。

3.3.3 特征选择方法

特征选择方法是一种应用搜索技术从给定的数据集中获得新的特征子集，并评估不同特征子集分数的方法。特征提取过程中可能会产生一些冗余特征。因此，可以根据其区分能力对特征进行排序和选择，在不影响分类器性能的情况下降低复杂性。在实际应用中，无法确定唯一最优的特征子集，不同的特征子集可能会对不同的机器学习算法分类效果产生影响。因此，特征选择技术一直是研究人员关注的焦点，目前特征选择方法主要分为三类：过滤法、包裹法和嵌入法^[64, 65]。过滤法依赖于数据的一般特征来评估和选择特征子集，而不涉及任何学习算法。互信息法是过滤法中最重要的方法之一，可以用来衡量变量之间的相互依赖关系。此外，常见的过滤法还有方差分析法和 Fisher 评分法。包裹法通过对数据应用预定的学习算法来选择特征子集，每次迭代所有剩余的特征。该方法使用统计技术来评估特征和目标值之间的关系，独立于机器学习算法，并且分类性能可以作为选择包裹法的特征子集的评价标准。包裹法采用基于随机森林分类器的递归特征消除方法，具有较高精度的预测变量选择能力，但是计算复杂度高。与包裹法相比，嵌入法可以同时进行特征选择和算法训练，

计算成本较低。基于树的特征选择方法是一种嵌入法。因此本章采用基于树的特征选择方法对脑电信号进行特征选择。它首先通过计算每个特征在树上的贡献度，然后对特征重要性排序，最后根据实际情况选择相关特征的个数。通常使用 *Gini* 指数作为重要性的评估指数，可以表示为：

$$GI_m = 1 - \sum_{k=1}^{|k|} p_{mk}^2 \quad (3-32)$$

式中 k —— 表示有 k 个类别；

p_{mk} —— 表示类别 k 在节点 m 中的比例。

3.3.4 多层感知器

多层感知器(multi-layer perceptron, MLP)是最常用的前馈神经网络，通常由输入层、一个或多个隐含层和输出层组成。其节点相当于神经元按层组织排列。MLP 是一种利用误差逆向传播算法构建的人工神经网络模型。人工神经网络是一种模仿人类大脑神经中枢分布式并行处理信息方式的人工网络，该网络由大量神经元连接而成，通过不断地调整神经元内部参数来实现输入到输出的映射关系。因此 MLP 的关键特征是一层中所有的神经元都与相邻层中所有的神经元相连接，并且这些连接带有权重。连接上的权重通过与非线性激活函数相结合，将输入的值映射到输出节点上。因此，增加隐藏层中神经元的数量，特别是增加更多的隐藏层，会迅速增加描述复杂决策边界的可能性。形式上，第 $l+1$ 层的输出激活是由输入激活推导出来的，如下所示：

$$a^{(l+1)} = \sigma(w^{(l)} a^{(l)} + b^{(l)}) \quad (3-33)$$

其中 l 表示输入层，每个输入层之间对应一个权重 w 和偏置 b 。MLP 所有的参数就是各个层之间的连接权重以及偏置，求解这些参数的最佳值的过程称为优化或训练。常用的方法是采用梯度下降法：首先从随机初始化所有参数开始，然后对每个输入样本进行迭代训练，不断计算梯度并更新参数，直到满足条件为止。对于 m 层多层感知器，第一个输入层为 $a^{(1)} = x$ 最后一个输出层为 $h_{w,b}(x) = a^{(m)}$ 。其中， w 和 b 是权重和偏置，它们通过使用反向传播算法逼近未知输入输出关系进行监督学习。最后通过式 3-33 将预测输出与期望输出之间的差异最小化。

$$J(W, b; x, y) = \frac{1}{2} \|h_{w,b}(x) - y\|^2 \quad (3-34)$$

本实验训练了 5 层 MLP 分类器，包含一个输入层，三个隐含层(30:90:30)和一个输出层，每个隐藏层都使用了 ReLU 激活函数。图 3-6 为多层感知器的结构。




图 3-6 多层感知器结构

线性整流(rectified liner unit, ReLU)可以通过数据的非线性映射解决优化问题。ReLU 激活函数广泛应用于神经网络中，该函数具有以下几个特点：

(1)非线性 ReLU 函数是一种非线性的激活函数，能够引入非线性因素，使得神经网络具有更强的表达能力。

(2)计算简单 ReLU 函数的计算非常简单，只需要进行一次比较运算和一次取最大值运算。

(3)梯度不会消失 与 Sigmoid 和 Tanh 等函数相比，ReLU 函数具有梯度不会消失的特点。这是由于在输入为正数时，梯度为 1，而在输入为负数时，梯度为 0，从而避免了梯度消失的问题。

(4)稀疏性 由于 ReLU 函数在输入为负数时输出为 0，因此可以使得神经元的输出更加稀疏，从而减少模型复杂度，提高模型的泛化能力。ReLU 函数激活模型如图 3-7 所示。

ReLU 采用单侧抑制形式，其特点是在输入为正数时，直接输出该值，输入为负数时，则输出 0。其计算方式为：

$$y = \max(0, x) = \begin{cases} 0 & (x < 0) \\ x & (x \geq 0) \end{cases} \quad (3-35)$$




图 3-7 ReLU 函数激活模型

3.4 评估指标

为了评估分类方法的性能，本研究使用了四个常用的评估指标。

(1)准确率 准确率是衡量分类模型性能最重要的指标，为分类器中正确预测样本与所有样本的比值：

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}} \quad (3-36)$$

(2)精确率 精确率为真阳性(TP)样本与真阳性(TP)和假阳性(FP)样本之和的比值：

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (3-37)$$

(3)召回率 召回率为真阳性(TP)样本与真阳性(TP)和假阴性(FN)样本之和的比值：

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (3-38)$$

(4)F 值 F 值为精确率和召回率的加权调和平均值：

$$\text{F Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3-39)$$

式中 TP —— 表示正确分类的阳性样本；

TN —— 表示正确分类的阴性样本；

FP —— 表示错误分类的阳性样本；

FN —— 表示错误分类的阴性样本。

3.5 实验结果

本研究使用了波恩大学癫痫数据集,针对癫痫发作间期,发作期和正常对照组三种脑电信号设计了四种分类任务:正常与癫痫发作期(A-E);正常与癫痫发作间期(A-D);癫痫发作间期与癫痫发作期(D-E);正常与癫痫发作间期与发作期(A-D-E)。首先对每段脑电数据进行双谱分析和时频分析,分区域进行特征提取,得到 BIS 特征和 CWT 特征并进行融合成 BISCWT 特征,然后使用 SVM、RF 和 MLP 三种分类器进行分类。为了防止过拟合现象,本章使用 10 折交叉验证法,在每次折叠中,90%的数据被用作训练集,其余 10%的数据被用作测试集。因此本章得到的所有实验结果均为 10 折交叉验证后的平均值。

3.5.1 特征选择结果

基于树的特征选择算法需要根据特征重要性选择合适的阈值,通常是由多次实验或经验来确定的。大多数文献直接选取特征排序后的前百分之十个特征或者前百分之二十个特征对应的特征值作为阈值,而 Zhou 等人^[65]选择特征值的中位数作为阈值,但上述方法均不能完全有效地选择出合适的特征。为了充分选择合适的特征阈值,本实验根据计算得出的重要性将已排序的特征逐个添加到分类器中,直到达到最高分类精度,根据最高精度选取对应的特征数量。10 折交叉验证后特征个数与准确率的关系如图 3-8 所示。可以看出,特征数量为 11 时,准确率最大。因此,使用前 11 个特征对分类器进行训练。

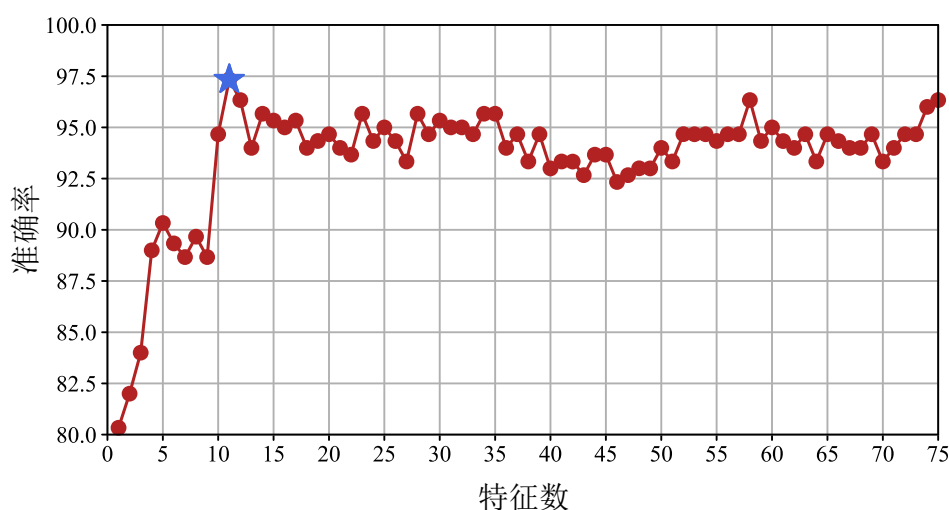


图 3-8 准确率与特征个数之间的关系

3.5.2 分类器性能的比较

本实验首先使用 BISCWT 融合特征比较了 MLP、RF 和 SVM 三种分类器的性能。如表 3-2 所示,在二分类 A-D 任务中,SVM 和 MLP 均获得了最高的准确率、召回率、F 值和精确率。这是因为正常脑电信号和癫痫发作脑电信号区别较大,区分比较容易在最难区分的 D-E 任务中,MLP 的准确率、召回率、F 值和精确率均为 97%,这比其它两种分类器的结果都要好,在三分类 A-D-E 任务中,MLP 获得了 97.34%的准确率,98.99%的召回率,96.41%的精确率和 97.68%F 值,高于 RF 和 SVM。从表中可以看出在四种分类任务中,MLP 的分类结果均比 RF 和 SVM 好,这表明了 MLP 和 BISCWT 结合可以获得较好、较稳定的癫痫发作检测性能。因此本章接下来的实验中均使用 MLP 分类器进行分类。

表 3-2 分类器的性能比较

分类任务	分类器	召回率	精确率	F 值	准确率
A-D-E	SVM	96.97	95.61	96.28	94.67
	RF	97.31	96.3	96.81	95.67
	MLP	98.99	96.41	97.68	97.34
	分类器	召回率	精确率	F 值	准确率
A-D	SVM	95.00	97.94	96.45	96.5
	RF	98.00	96.08	97.03	97.00
	MLP	99.00	98.02	98.51	98.5
	分类器	召回率	精确率	F 值	准确率
A-E	SVM	100	100	100	100
	RF	100	99.01	99.5.0	99.50
	MLP	100	100	100	100
	分类器	召回率	精确率	F 值	准确率
D-E	SVM	96.00	96.97	96.49	96.50
	RF	94.00	96.91	95.43	95.50
	MLP	97.00	97.00	97.00	97.00

3.5.3 不同特征提取方法的性能比较

在这一部分中,比较了 BISCWT 融合特征与其他两个单一特征(BIS 特征和 CWT 特征)的分类能力。表 3-3 为实验结果,包括平均准确率、精确率、召回率和 F 值。可以看出,与基于连续小波变换的 CWT 特征相比, BISCWT 融合特征的性能有显著的提高。尤其是,在三分类任务中 BISCWT 融合特征比 CWT 特征的准确度高出 12.68%,召回率高出 4.46%,精确率高出 7.51%,F 值高出约 6%。与基于双谱的 BIS 特征相比,在所有任务中的准确度也有 1.5%以上的提升。其中在 D-E 分类任务上性能提高最明显,召回率提高了 3%,精确率高出了 1.09%,F 值也有提高了 2.09%。结果表明,使用特征融合的 BISCWT 方法的性能优于单独使用的 CWT 和 BIS 方法,在所有分类任务中都获得了最好的分类性能。

表 3-3 不同特征提取方法的性能比较

特征	分类任务	召回率	精确率	F 值	准确率
CWT+MLP	A-D-E	94.53	88.90	91.60	84.66
	A-D	88.00	80.73	84.21	83.50
	A-E	98.00	98.00	98.00	98.00
	D-E	93.00	95.88	94.41	94.50
BIS+MLP	分类任务	召回率	精确率	F 值	准确率
	A-D-E	97.97	95.68	96.8	95.66
	A-D	98.00	96.07	97.09	97
	A-E	100	100	100	100
BISCWT+MLP	D-E	94.00	95.91	94.95	95
	分类任务	召回率	精确率	F 值	准确率
	A-D-E	98.99	96.41	97.68	97.34
	A-D	99.00	98.02	98.51	98.5.0
	A-E	100	100	100	100
	D-E	97.00	97.00	97.00	97.00

3.5.4 混淆矩阵

图 3-9 显示了使用 BISCWT 特征进行分类得到的混淆矩阵。对角线值是每项任务的准确度。从混淆矩阵中的对角线值可以看出，BISCWT 特征在所有分类任务中均获得了很好的分类结果：在 A-D 分类任务中仅有个别类型识别错误，在 A-D 任务中全部识别，在最难区分的 D-E 分类中对 E 类的识别率稍微低一点，这是因为 D 类为发作间期，E 类为发作期它们具有一定的相似性。值得注意的是，它不仅对每个分类任务都有很好的精度，而且具有最好的全局平均精度。因此，与单一特征相比，所提取的 BISCWT 融合特征能够更全面地描述脑电信号信息，实现了特征间的互补，从而进一步提高了分类性能。

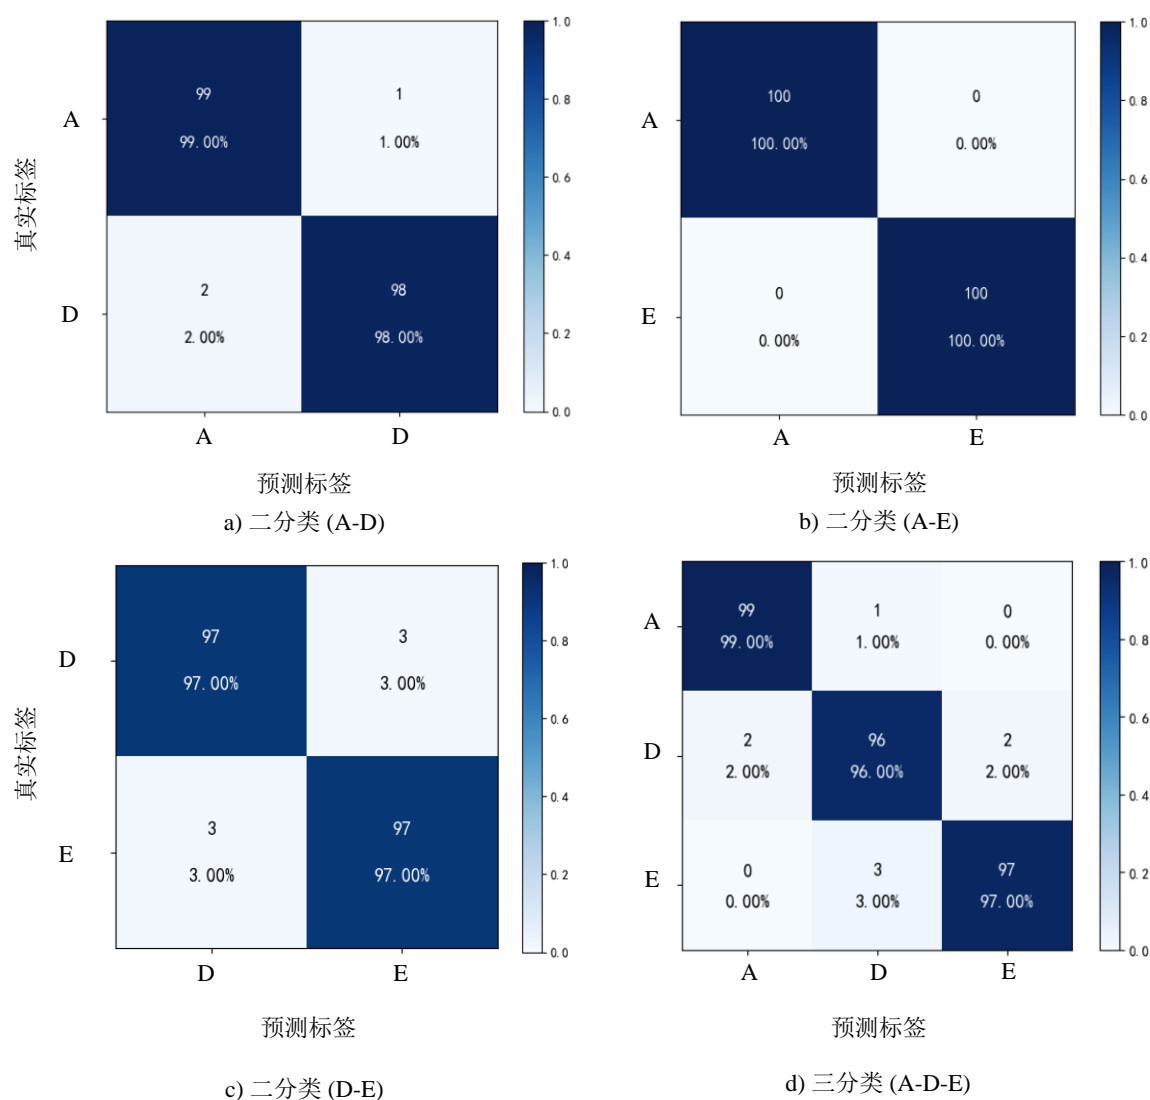


图 3-9 BISCWT 特征的混淆矩阵

3.5.5 与其他方法的比较

为了便于比较,本章列出了使用相同的数据集的研究,如表 3-4 所示。结果表明,本章多域联合分析算法在三分类任务和二分类的任务中都获得了较好的分类性能,尤其是在最难处理的二分类 D-E 任务中取得了最高的精度。

Jing 等人使用滑动窗口加权方法增强信号,使用离散小波变换选择合适的频带特征进行分类^[66]。Nabil.R 等人将近似熵、最大 Lyapunov 指数和高阶谱分析的相位熵进行合并,用作支持向量机的输入向量^[67]。Tuncer 等人将局部图结构与离散小波变换相结合,形成一种新的集成特征提取网络进行分类^[68]。Raghu 等人将 EEG 按照时间序列排序计算了矩阵行列式特征,结合 SVM、KNN 和 MLP 进行分类^[69]。Chandel 等人提出了一种基于三进小波分解的特征发作起始点和偏离点相结合的检测方法,提取了标准差、方差和高阶矩特征,利用线性判别分析和 KNN 分类器对癫痫和非癫痫脑电信号进行分类^[70]。Sharmila 等人使用离散小波变换提取信号在多个尺度上的特征,并使用朴素贝叶斯和 KNN 进行分类。比较结果表明了多域联合分析方法拥有更好的分类能力。其中,MLP 在三分类任务中(A-D-E)效果最好,准确率为 97.34%,MLP 在二分类 A-E 任务中的准确率达到了 100%。值得注意的是,本章方法使用的 MLP 分类器结构简单,它仅包含了 3 个隐藏层,因此需要的学习参数数量和训练时间显著减少。

表 3-4 波恩大学癫痫数据集不同癫痫分类研究方法及准确率

作者	年份	方法	分类任务	准确率
Jing et al ^[66]	2022	离散小波变换+ SVM	A-D-E	96.59%
Nabil et al ^[67]	2020	小波分解、近似熵和 Lyapunov 指数+ SVM	A-D-E	96.80%
Tuncer et al ^[68]	2020	局部图结构和离散小波变 换+ SVM	A-D-E	96.00%
S Raghu et al ^[69]	2019	矩阵行列式特征+MLP	A-E	99.10%
Chandel et al ^[70]	2019	三元小波分解+ KNN	A-D-E	96.00%

表 3-4 (续表)

作者	年份	方法	分类任务	准确率
Sharmila et al ^[71]	2018	波形长度、过零数和斜率 符号变化数等时域特征+SVM	A-E	100%
			D-E	92.75%
			A-D-E	97.34%
本章方法		多域联合分析特征+ MLP	A-E	100%
			A-D	98.50%
			D-E	97.00%

3.6 本章小结

本章构建了一种多域联合分析的癫痫脑电信号分类方法。该方法结合了双谱特征和连续小波变换特征；采用基于树的特征选择算法去除冗余特征，以达到降维和提高性能的目的；最后，利用多层感知器进行分类。本实验从四个方面验证了 BISCWT 方法的性能：MLP、RF 与 SVM 在相同融合特征 BISCWT 下的性能比较；将 BISCWT 融合特征与其他两个单一特征的性能进行比较；BISCWT 特征的混淆矩阵；将多域联合分析方法与其他现有方法的性能进行比较。实验结果表明，多域联合分析算法不仅提高了脑电信号的分类效果，而且降低了数据维度和计算复杂度。

第4章 基于时间卷积网络的癫痫分类方法

4.1 引言

在上一章中,使用双谱和连续小波变换融合特征实现了一种基于多域联合特征的癫痫脑电信号分类方法。所得结果虽然比近几年使用的方法有所提高,但这种机器学习方法需要选择、提取出有效地独立特征,步骤较为繁琐。最近,由于深度学习技术在其他应用中的巨大成功,许多研究人员已经使用深度学习算法对脑电信号进行分类。与传统机器学习方法相比,深度学习方法通过构建端到端的网络,避免了手动提取特征的步骤,简化了 EEG 分类流程。这种方法具有很强的自适应性和泛化能力,可以自动学习和提取数据中的有效特征,并实现高精度的分类任务。在深度学习方法中,基于 CNN 的算法作为癫痫分类检测的主流算法,其存在参数众多,空间占用大,计算时间长等缺点。还有一些基于 RNN 的算法,容易产生梯度消失或爆炸的问题。

基于以上原因,本章构建了一种基于注意力的时间卷积网络用于癫痫脑电信号分类。与典型的 RNN 不同,时间卷积网络可以随着参数的线性增加而指数地扩展感受野的大小,同时它不受梯度消失或爆炸的影响。该模型利用多种技术以相对较少的参数提高癫痫分类的性能。该深度学习模型分为三步:首先,使用卷积模块将脑电信号编码为高级时间序列,然后使用注意力模块突出显示时序序列中最有价值的信息,最后使用时间卷积模块从突出显示的信息中提取高级时态特征。该模型利用多头自注意力机制和基于卷积的滑动窗口来提高癫痫分类的性能。

4.2 注意力时间卷积网络模型

注意力机制是一种模仿人类大脑的行为机制,它可以选择性地关注一些重要的元素,忽略其他元素。将注意力机制与深度学习模型结合,通过学习有助于自动集中输入数据的重要部分。第一个基于注意力的模型(RNN 模型)由 Bahdanau 等人提出,称为加性注意^[72]。同年,Luong 等人提出了一种带有乘法计分函数的注意层,称为乘性注意^[73]。2017 年,谷歌提出了一个具有多头注意力的纯注意力模型,该模型由多个自注意力层组成^[57]。这些基于注意力的模型最初是为自然语言处理而提出的,随后研究人员将其用于其他领域。目前已经提出了几种注意模块,如挤压激励和卷积块注意模块。

最近,将注意力机制应用于脑电信号分析逐渐演变成一个新兴趋势。已经有研究人员使用基于注意力的深度学习模型对 EEG 信号进行分类。例如, Zhang 等人利用 LSTM 和图神经网络表示的自注意力来解码运动想象(motor imagery, MI)任务^[74]。在最近的一项研究中, Altuwaijri 等人提出了一种基于注意力的多分支 CNN 模型,用于使用原始数据对 MI 任务进行分类。作者在三个 CNN 分支中使用三个 SE 注意块作为中间层。虽然目前的研究在解码 EEG 信号方面取得了较好的效果,但分类性能仍然有限,需要进一步提高^[75]。目前注意力机制多用于运动想象的分类,并未涉及癫痫脑电信号分类,因此本实验将注意力机制引入深度神经网络中进行癫痫分类。

本章构建了一种基于注意力机制的时间卷积网络模型 ATCNet,该模型由三个主要模块组成:卷积模块(convolutional, CV)、注意力模块(attention, AT)和时间卷积模块(temporal convolutional, TC)。CV 模块通过三个卷积层对 EEG 信号中的低级时间信息进行编码。CV 模块的输出是具有更高级别表示的时序序列。然后,AT 模块使用多头自注意力机制(multi-head self-attention, MHSA)突出显示时间序列中最重要的信息。最后,TC 模块利用时间卷积网络提取时间序列中的高级时间特征,并使用 SoftMax 分类器将其馈送到全连接(fully connected, FC)层。ATCNet 模型架构如图 4-1 所示。

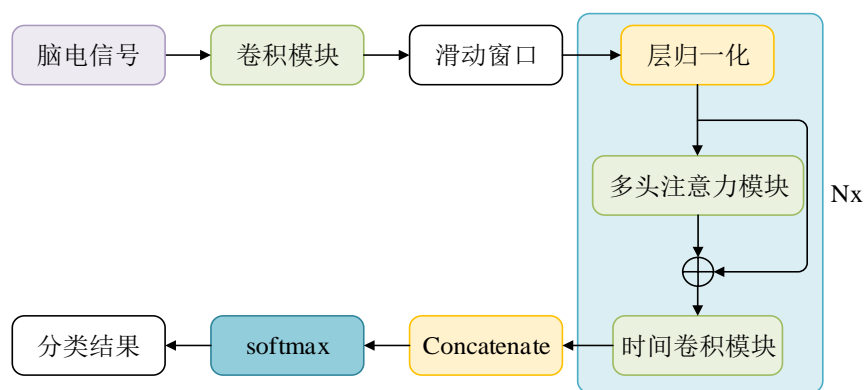


图 4-1 ATCNet 模型架构

从 CV 模块输出的时间序列分成多个窗口,并且每个窗口都分别馈送到 AT/TC 模块。然后,将所有窗口的输出串联;最后馈送到 SoftMax 分类器。这样可以有效地增加数据并提高准确性。

本章将原始的 EEG 信号进行滤波(0.5~40Hz)输入到 ATCNet 模型中。ATCNet 模型以 $X_i \in \mathbf{R}^{C \times T}$ 为输入, 其中 C 为通道数(脑电电极), T 表示时间点。ATCNet 模型的目标是将输入的 EEG 片段 X_i 映射到其对应的类 y_i , 给定一组 m 标签的实验训练 $S = \{X_i, y_i\}_{i=1}^m$, 其中 $y_i \in \{1, \dots, n\}$ 是试验 X_i 的相应类别的标签, n 是集合 S 的定义类别总数。

卷积模块类似于 EEGNet 模型^[76]。但不同于 EEGNet，它使用了二维卷积，而不是可分离卷积。卷积模块由三个卷积层组成，如图 4-2 所示。第一层为时间卷积层，它使用大小为 $(1, K_C)$ 的 F_1 滤波器进行时间卷积，其中 K_C 是时间轴上的滤波器长度。 K_C 为采样率的四分之一。该层的输出是时间特征图 F_1 。第二卷积层， F_2 滤波器的大小为 $(C, 1)$ ，其中 C 是 EEG 通道的数量。

图 4-2 卷积模块示意图

为 16。使用大小为 $(1, P_2)$ 的平均池化层进行降采样。 P_2 用于控制 CV 模块产生的时间序列的长度。第二和第三卷积层之后是批归一化层，用来加速网络训练，然后使用指数线性单元(exponential linear unit, ELU)作为激活函数。

CV 块输出时间表示的序列 $Z_i \in R^{T_c \times d}$ ，该序列由 T_c 个时间向量组成，每个时间向量的维度为 $d = F_2 = F_1 \times D$ 。根据前人的经验，将 d 设置为 32。时间序列 Z_i 的长度由下式确定：

$$T_c = \frac{T}{8P_2} \quad (4-1)$$

式中 T —— 指原始 EEG 信号的时间点。

4.2.3 基于卷积的滑动窗口模块

本实验使用滑动窗口将时间序列划分为多个窗口，而不是将 Z_i 的整个 T_c 样本输入到后面的层。这样可以增加数据并提高精度。然而，这造成了一个问题：滑动窗口的使用增加了计算量，因为它要求输入数据通过模型 n 次，而不是一次，其中 n 表示窗口的数量。结果是计算量递增了 n 倍。因此，本实验在卷积层使用滑动窗口的方法。在这种方法中，卷积计算针对所有窗口执行一次，这通过并行化过程来减少训练和推理时间。该技术最初用于基于滑动窗口的目标检测^[77]。

基于滑动窗口的卷积模块旨在把将神经网络的全连接层转化为卷积层。以一个 $14 \times 14 \times 3$ 的输入数据为例，经过一个尺寸为 5×5 、数量为 16 的卷积层处理后，映射成 $10 \times 10 \times 16$ 的输出结果。然后通过一个参数为 2×2 的最大池化层，将尺寸缩小到 $5 \times 5 \times 16$ 。接着，将原本的全连接层替换为一个尺寸为 5×5 、数量为 400 的卷积层和一个尺寸为 1×1 、数量为 400 的卷积层，最后通过 softmax 分类器输出。从数学的角度来看，它和全连接层的作用是一样的。因为在这 400 个节点中，每个节点都有一个 $5 \times 5 \times 16$ 的过滤器，因此每个值都是上一层与这 400 个 $5 \times 5 \times 16$ 的激活值经过线性函数的输出结果。最后，再添加一个 1×1 的卷积层。假设有 400 个 1×1 的过滤器，在这些过滤器的作用下，下一层的维度是 $1 \times 1 \times 400$ 。然后，经过一个 1×1 的过滤器的处理，得到一个 softmax 激活值。通过卷积网络，最终得到一个 $1 \times 1 \times 4$ 的输出层。滑动卷积模块的示例如图 4-3 所示。




图 4-3 滑动卷积模型

本实验使用步长度为 T_w 的滑动窗口将时间序列 Z_i 划分为多个窗口 $Z_i^w \in R^{T_w \times d}$, $w=1, \dots, n$ 表示窗口索引, n 是窗口总数。然后, 每个窗口 Z_i^w 分别进入后面的 AT 块, 然后进入 TC 块。窗口长度 T_w 由下式确定:

$$T_w = T_c - n + 1, T_c > n \geq 1 \quad (4-2)$$

$$T_w = \frac{T}{8P_2} - n + 1 \quad (4-3)$$

其中 $T=112$ 。如果 CV 块执行大小为 $P_1=8$ 和 $P_2=7$ 的两个时间池, 则 CV 将产生 $TC=20$ 个向量。每个向量代表原始 EEG 信号 X_i 中的时间点。

4.2.4 注意力模块

注意力是心理学中一个重要的认知过程, 它指的是人专注于某一事物而忽略其他事物的能力。在深度神经网络中, 注意力机制是一种仿照人脑行为的机制, 它选择性地关注一些重要元素而忽略其他元素。在现实生活中, 人们可以自愿或非自愿地集中注意力, 前者取决于自我意识, 而后者则受到周围人或事物的影响。基于自愿和非自愿注意力线索的启示, 提取了三个组成部分来模拟注意力机制: 查询(Query 自愿线索)、键值(Key 非自愿线索)和值(Value 感觉输入)。如图 4-4 所示, Query 和 Key 的交互产生了注意力集中, 从而偏向于 Value 的选择。

注意力机制可以基于注意力分数(MHSA)或其他机器学习算法(例如强化学习)来实现。本章采用基于注意力分数的方法, 即多头自注意力机制, 因为它在计算机视觉、脑机接口等领域都取得了巨大成功。

注意力模块由缩放点积注意力机制和多头注意力机制组成的, 它包括多个自注意力层。Transformer 模型将这种自注意力层称之为头(Head)。每个自注意力层由 Query、Key 和 Value 三部分组成。Query 和 Key 之间的交互作用产生注意力分数, 从而偏向于 Value 的选择。这种交互方式的详细实现如图 4-5 所示。

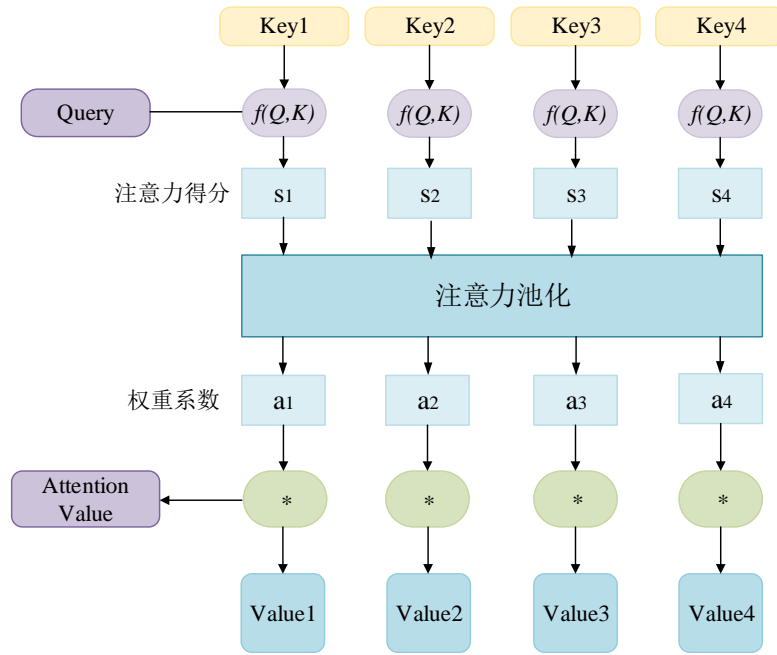


图 4-4 注意力机制示意图

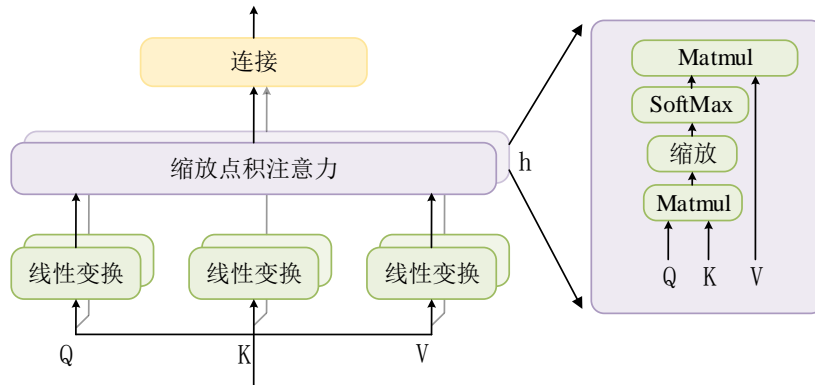


图 4-5 缩放点积注意力

给定由 CV 块编码的窗口表示 Z_i^w ，对每批 Query/Key/Value 向量使用线性变换，计算公式如下所示：

$$q_t^h = W_Q^h LN(Z_i^w) \in R^{d_H}, W_Q^h \in R^{d \times d_H} \quad (4-4)$$

$$k_t^h = W_K^h LN(Z_i^w) \in R^{d_H}, W_K^h \in R^{d \times d_H} \quad (4-5)$$

$$v_t^h = W_V^h LN(Z_i^w) \in R^{d_H}, W_V^h \in R^{d \times d_H} \quad (4-6)$$

其中， LN 表示层归一化(layer normalization, LN)， $t=1, \dots, T_w$ 是窗口 w 中的时间向量上的索引， T_w 是窗口的长度(时间向量的总数)， $h=1, \dots, H$ 是多头注意力的头部数。

根据经验，注意力头部的缩小设定为 $d_H = \frac{d}{2H}$ 。

给定一个 Query($q_i^h \in R^{q=d_H}$), T_w 个 Key-Value 对为 $(k_1^h, v_1^h), \dots, (k_{T_w}^h, v_{T_w}^h)$, 其中 $k_i^h \in R^{k=d_H}$ 。注意力池化层 f 中生成上下文向量 c_i^h 为值 v_i^h 的加权和。

$$c_i^h = f(q_i^h, k_i^h, v_i^h) = \sum_{t'=1}^{T_w} \alpha_{it'}^h v_{t'}^h \in R^{d_H}, \sum_{t'=1}^{T_w} \alpha_{it'}^h = 1 \quad (4-7)$$

$\alpha_{it'}^h$ 为查询 q_i^h 和键值 $k_{t'}^h$ 的注意力权重, 它通过对相应的匹配分数 $e_{it'}^h$ 应用 SoftMax 函数计算的。

$$\alpha_{it'}^h = \text{softmax}(e_{it'}^h) = \frac{\exp(e_{it'}^h)}{\sum_{k=1}^{T_w} \exp(e_{ik}^h)} \in R \quad (4-8)$$

匹配分数 $e_{it'}^h$ 的计算公式为:

$$e_{it'}^h = a(q_i^h, k_{t'}^h) \in R \quad (4-9)$$

其中 a 为注意力评分函数。选择不同的注意力得分函数会产生不同的注意力池化选择结果。常见的得分函数有: 加性注意力机制和点积(乘性)注意力机制。加性注意力机制通过使用具有单个隐藏层的前馈网络计算兼容性函数来实现, 点积注意力机制只有一个缩放因子 $\frac{1}{\sqrt{d_k}}$ 。尽管这两种方法在理论复杂度上相似, 但在 Transformer 模型中, Vaswani 等人表明在 d_k 值较小时, 加性注意力机制和未经缩放的点积注意力机制表现相似^[57]。然而对于较大的 d_k 值, 缩放点积注意力机制的表现优于加性注意力机制。因此, 本实验使用缩放点积注意力。需要注意的是点积运算要求 Query 和 Key 都具有相同的向量长度。缩放点积注意力的得分函数 a 公式为:

$$a = \frac{(q_i^h)^T k_{t'}^h}{\sqrt{d_H}} \in R \quad (4-10)$$

进行完点积运算后, 需要除以 $\sqrt{d_H}$, 以确保无论向量长度如何变化, 点积的方差保持不变。

对于每个头部, 具有 $n=T_w$ 个 Query 和 $m=T_w$ 个 Key-Value(全局注意力)的小批次的缩放点积注意力的上下文向量由式(4-11)确定, 其中长度为 d_H 和值 v 的 Query/Key (在本章中为 $v=d_H=8$)。因此, 自注意力机制可以同时为注意力进行并行计算并应用到所有输入中。

$$C^h = \text{softmax}\left(\frac{Q^h (K^h)^T}{\sqrt{d_H}}\right) V^h \in R^{((n=T_w) \times (v=d_H))} \quad (4-11)$$

$$Attention(Q, K, V)^h = softmax(\frac{Q^h (K^h)^T}{\sqrt{d_H}}) V^h \in R^{((n=T_w) \times (v=d_H))} \quad (4-12)$$

其中, $Q \in R^{n \times d_H}, K \in R^{n \times d_H}, V \in R^{m \times v}$ 。然后, 将来自所有头部的上下文向量串联并使用残差连接将结果添加到输入窗口 Z_i^w 来计算MHSA, 如下式:

$$Z_i^w = W_o[C^1, \dots, C^H] + Z_i^w \in R^{T_w \times d}, W_o \in R^{d_H \times d} \quad (4-13)$$

4.2.5 时间卷积模块

时间卷积模块由时间卷积网络(temporal convolutional network, TCN)构成, 时间卷积网络在许多时间序列分类任务中表现出了较好的性能^[78]。与传统的 CNN 不同的是, TCN 能够通过线性增加参数和相乘一累加数量的方式指数级地扩展其感受野的大小, 而传统的 CNN 仅线性增加感受野的大小。此外, 与其他时间序列分类网络不同, 例如循环神经网络, 当对长序列进行训练时, TCN 不会产生度爆炸或度消失的问题。

时间卷积网络由多个残差模块组成, 残差模块由两个膨胀因果卷积层组成, 每个层后面跟着一个批归一化和 ELU 激活, 如图 4-6 所示。

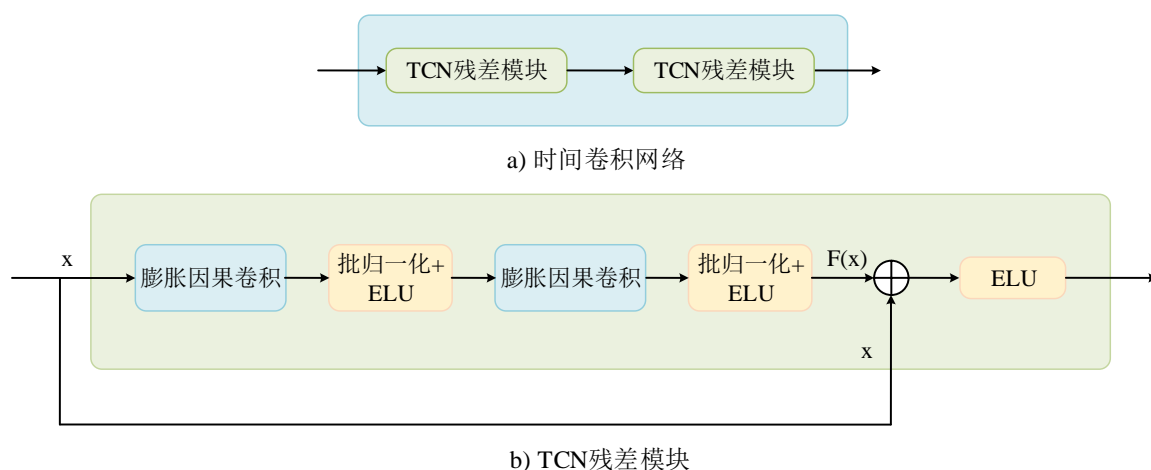


图 4-6 时间卷积网络

(1)因果卷积 TCN 使用一维全卷积网络来保证输出与输入长度相同。每个隐藏层的大小都与输入层相同, 并对输入进行零填充以保持前后层长度一致(零填充的长度根据卷积核大小而定)。此外, TCN 采用因果卷积防止信息从未来传播到过去, 确保在 t 时刻的输出仅取决于时间 t 和更早的输入。

(2)膨胀卷积 常规因果卷积的一大局限在于其仅能通过线性方式增加网络深度上的感受野(receptive field size, RFS)大小。然而,这种限制导致需要使用极深的网络或具有超大卷积核大小的网络才能获得较大的感受野。为了应对这一问题,TCN 采用了一系列膨胀卷积操作。通过引入膨胀因子 d ,采用指数增加的方案,使感受野的大小按比例呈指数级增长,同时增加了网络的深度。因此,膨胀因果卷积可以学习长序列中的相关性。

(3)残差块 时间卷积网的每个残差块均由两层膨胀卷积组成,每层膨胀卷积都包含了因果卷积层、批归一化层(batch normalization)、非线性激活函数和 dropout。这种结构可以有效地增加模型的深度和复杂度,并且在保持模型稳定性的同时提高了其性能。批归一化操作可以对网络的每一层进行标准化处理,有效地避免了梯度消失问题;非线性激活函数可以增加模型的非线性表达能力,从而更好地捕捉数据的特征;dropout 操作可以减少模型的过拟合现象,提高模型的泛化能力。

尽管 TCN 只有一维卷积,但将第二维作为深度维度,它们仍然可以有效地处理 2D 特征图。然后使用跳跃连接将输入与输出特征图相加,同时检查输入和输出的深度是否相等,如果不同则使用 1×1 卷积进行处理。图 4-6 为将两个残差块堆叠在一起的示意图。由于每个残差块的膨胀率 d 呈指数级增长,因此 TCN 感受野的大小会随着堆叠的残差块 L 的数量呈指数增长。RFS 由两个参数控制:残差块的数量 L 和卷积核 kernel 的大小 K_T ,如定义 4-14。

$$RFS = 1 + 2(K_T - 1)(2^{L-1}) \quad (4-14)$$

在 ATCNet 模型中,TC 块是由一个时间卷积网络组成,它带有残差块,所有卷积层都具有 32 个大小为 $K_T = 4$ 的滤波器。

对于这个 TCN, RFS 为 19,即在一个序列中,TCN 最多可以处理 19 个元素。因此,输入到 TC 块的时间序列应该小于或等于 19,以允许 TCN 无损失地处理所有的时间信息。TCN 处理序列流程图如图 4-7 所示。对于比 RFS 长的序列,则可以将它们分成多个窗口,需要每个窗口的长度都小于 RFS。然后,每个窗口分别进入 TC 块。在本实验中,将 RFS 固定为 19。图 4-7 显示了一个包含 16 个时间元素($T_w = 16$)的序列进入时间卷积网络的过程。其中每个元素都是一个大小为 F_2 的向量(CV 块中滤波器的数量)。序列中的最后一个元素为 TCN 的输出值,它是一个大小为 F_T 的向量(TCN 中滤波器的数量)。在本实验中, $F_2 = F_T = 32$ 。

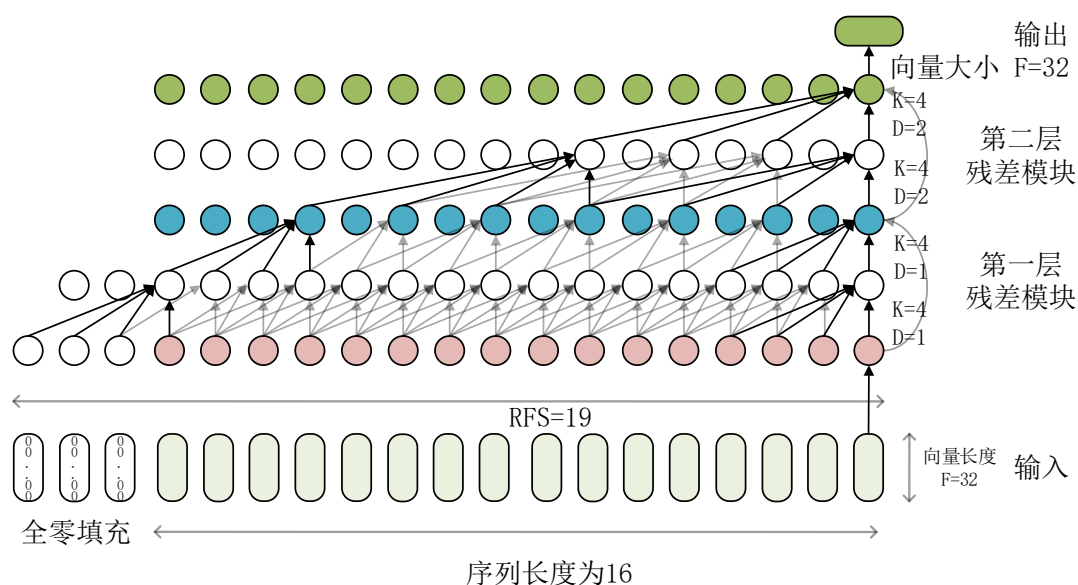


图 4-7 TCN 处理序列流程图

4.3 实验内容及参数

本章实验所有训练与测试过程均在波恩大学癫痫数据集上进行。第三章中已有对该数据集的具体介绍，本章将不再进行讨论。为了评估该方法的性能，本章使用 10 折交叉验证法对脑电信号进行了多次实验，所得结果均为 10 折交叉验证结果的平均值。本章选取了四种常见的分类任务进行了研究。在实验 1 中，将脑电信号分为两类，Set A 为健康类，Set D 为癫痫发作间期。在实验 2 中，Set A 为健康类，Set E 为癫痫发作期。在实验 3 中，Set D 为癫痫发作间期，Set E 为癫痫发作期。在实验 4 中，将脑电信号分为三类，Set A、Set D 和 Set E 分别被分为健康类、癫痫发作间期和癫痫发作期。本实验模型使用了 Adam 优化器进行训练，学习率为 0.0009，批处理大小为 64，使用交叉熵作为损失函数，epoch 为 600。本章中所有实验使用的超参数都显示在表 4-1 中。

表 4-1 超参数设置

卷积模块	参数	注意力模块	参数	时间卷积网络模块	参数
滤波器的数量(F_l)	16	head数量(H)	2	残差模块的数量(L)	2
卷积核尺寸(K_c)	64	head大小(d_H)	8	卷积核尺寸(K_T)	4
池化层尺寸(P_2)	7	Dropout(p_a)	0.5	滤波器的数量(F_T)	32
Dropout(p_c)	0.3			Dropout(p_l)	0.3
窗口数量(n)	4				

4.4 评估指标

本章中的 ACTNet 模型使用准确率和 Kappa 值进行评估。

$$ACC = \frac{\sum_{i=1}^n \frac{TP_i}{I_i}}{n} \quad (4-15)$$

式中 TP_i —— 真阳性，即第 i 类中正确预测的样本数；

I_i —— 第 i 类中的样本数；

n —— 表示第 i 类中的样本数。

$$k_score = \frac{1}{n} \sum_{a=1}^n \frac{P_a - P_e}{1 - P_e} \quad (4-16)$$

式中 P_a —— 实际同意百分比；

P_e —— 预期同意百分比；

n —— 表示类别。

4.5 实验结果

4.5.1 注意力头部数量的选择

图 4-8 比较了头部不同数量对多头注意力层的影响，即通过改变 Query/key/Value 向量的每个注意力头部的大小来比较 MHSA 的性能。结果表明，使用两个大小为 8 的头部的效果最好。这是因为 EEG 数据集的样本数量有限，需要一个较轻的 MHSA 层就能很好地收敛。

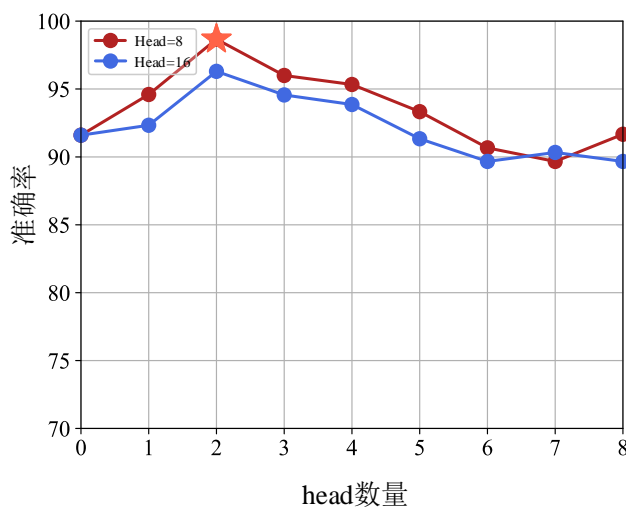


图 4-8 注意力头部数量的比较

4.5.2 损失函数

在训练过程中，生成了准确率和损失函数值曲线来评估模型的性能和优化情况。交叉熵损失函数广泛应用于深度学习模型中，以测量真实输出和期望输出之间的差异程度，交叉熵损失函数的值越小，表示两个输出越接近，效果越好，比较训练集和测试集的损失函数有助于判断模型处于过拟合状态还是欠拟合状态。如图 4-9 所示，可以看到在训练和验证集上，随着训练轮数的增加，准确率不断提高，训练损失逐渐降低至 0.1 以下，而且在模型训练时，训练的损失值和验证损失值之间的差异很小。这表明 ATCNet 模型在训练过程中逐渐收敛，且没有出现明显的过拟合或欠拟合现象。




图 4-9 准确率和损失函数曲线

4.5.3 分类结果分析

从表 4-2 中可以看出，本章实现的 ATCNet 模型在二分类的实验中均获得了 100% 的分类效果，在三分类实验中获得 98.67% 的准确度。实验结果表明该模型在不同类型的脑电信号多次实验中，依然得到了较高的分类准确率，说明了本方法能充分提取脑电信号特征，具有很好的泛化性能。

表 4-2 ATCNet 网络的分类结果

分类任务	准确率	K-score
A-D	100%	1
A-E	100%	1
D-E	100%	1
A-D-E	98.67%	0.985

4.5.4 混淆矩阵

本实验构建混淆矩阵以观察数据集中各个类别的分类准确率，如图 4-10 所示。在所有二分类任务中 ATCNet 模型都表现出了非常高的性能，在最难的 D-E 分类任务中也能全部识别出来，在三分类任务中也表现出来较好的分类效果。实现结果表明了 ATCNet 模型对于这三种类型的 EEG 信号具有不错的识别能力，能够有效地将不同类型的 EEG 信号区分开来。

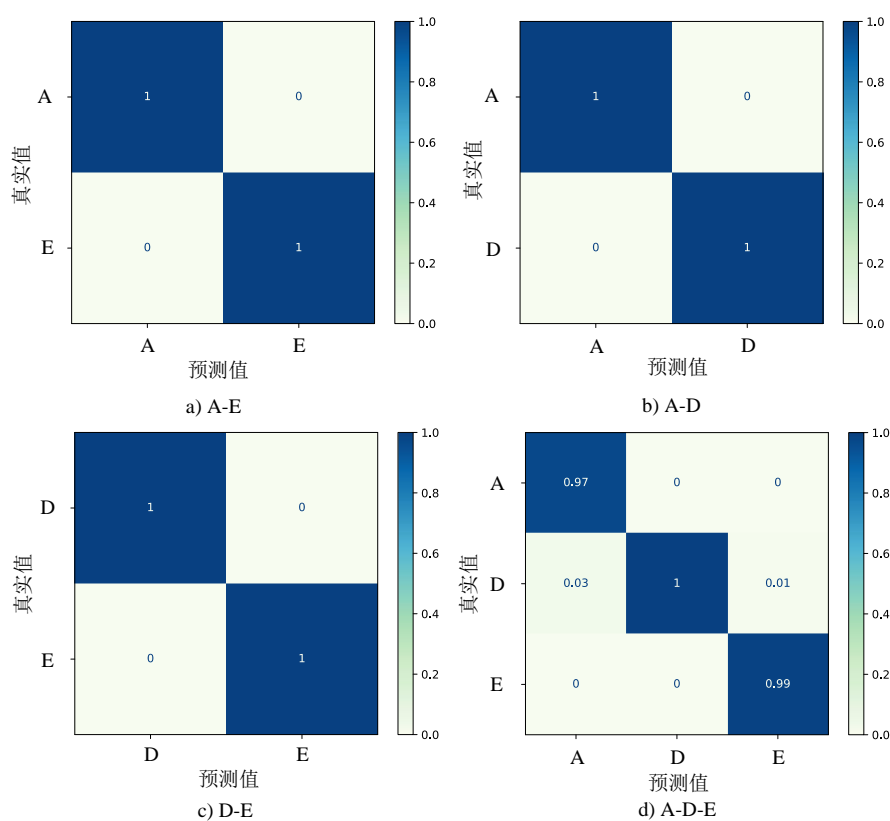


图 4-10 混淆矩阵

4.5.5 与现有算法对比

表 4-3 为本章算法与现有文献在波恩脑电数据集上分类结果的对比。在二分类任务中，该方法的准确率为 100%，在较难的三分类任务中也获得了 98.67%的准确率，相较于其他研究的方法本研究使用较少的参数就能获得高性能的结果。

表 4-3 不同癫痫分类研究方法及准确率

作者	年份	方法	分类任务	准确率
Khan et al ^[79]	2021	希尔伯特变换和相关性	A-D-E	96.00 %
			A-E	100%
Ilakiyaselvan et al ^[80]	2020	相空间重构+ AlexNet	D-E	97.22%
			A-D-E	95.93%
Thara el al ^[81]	2019	双向堆叠的 LSTM	A-D-E	93.00%
Acharya et al ^[82]	2018	13 层 1D CNN	A-D-E	88.67%
Ahmedt et al ^[83]	2018	1D LSTM	D-E	95.84%
Ullah et al ^[37]	2018	P-1D-CNN	A-D-E	94.10%
			D-E	97.40%
			A-D	100%
			A-E	100%
本章方法		ACTNet	D-E	100%
			A-D-E	98.67%

表 4-4 中均为使用深度神经网络模型进行癫痫分类的方法。Khan 等人利用 LSTM 模型对基于相关性的 Q-Score 选择的特征进行分类，优化了分类的精度，但仍低于本章方法^[79]。Ilakiyaselvan 等人使用相空间重构的轨迹图像作为 AlexNet 卷积神经网络的输入以解决癫痫检测问题，在 A-E 分类任务中效果好但其他任务中略低于本章方法^[80]。2019 年 Thara 等人对循环神经网络进行了改进，使用堆叠的双向 LSTM^[81]。Ahmedt 等人在 2018 年提出了一种基于原始信号的癫痫发作检测的深度学习模型 LSTM，其准确率达到了 95.84%，与传统机器学习的结果相当^[83]。Ullah 等人针对一

般模型在二分类任务精度好在三分类任务效果下降和 CNN 模型参数较多的问题,构建了一种金字塔型深度一维卷积网络,取得了不错的结果,但本章方法在二分类和三分类任务中的效果均略高于此方法^[37]。因此,证明了基于注意力时间卷积网络的泛化能力和分类有效性。

4.6 本章小结

本章构建了一种基于注意力机制的时间卷积网络模型。它由卷积模块、多头自注意力模块和时间卷积模块组成。该方法将多头自注意力机制和基于卷积的滑动窗口加入到时间卷积网络中,有助于提取脑电信号的有效信息,而且该模型比其他深度模型更易解释。结果表明,基于注意力机制的时间卷积网络模型在波恩大学癫痫数据集二分类任务中均获得了 100%的准确率,在三分类任务中 10 折交叉验证的平均准确率达到 98.67%的准确率。而且,此模型仅使用了相对较少的参数获得了较高性能的结果,说明了基于注意力机制的时间卷积网络模型从 EEG 中提取信号特征的有效性。

结 论

癫痫作为一种神经系统疾病具有反复性，严重影响了患者的生活质量。对癫痫患者的脑电图分析过于依赖神经学家的目测检查，这项任务十分繁琐和费时，因此，需要一种癫痫发作自动检测算法来解决这些问题。本文以癫痫脑电信号为基础，从机器学习和深度学习两个角度出发，对如何提高癫痫脑电信号自动分类效果进行探索，从两个角度分别构建了性能更加优越并具有一定临床意义的癫痫脑电自动分类方法，为癫痫脑电自动分类研究提供了新的思路。本文研究成果如下：

(1)构建了一种多域联合分析的癫痫脑电信号分类方法。首先采用双谱和连续小波变换两种方法对脑电信号进行分析，通过双谱等高线图和双谱对角切片图揭示了癫痫患者发作间期和发作期不用的非线性耦合现象；然后按照五种不脑电节律分别提取时域和非线性动力学特征并将其进行组合；接着使用基于树的特征选择算法来选择贡献最大的特征，最后通过比较支持向量机、随机森林和多层感知器的分类结果，最终决定使用其中效果最好的多层感知器进行分类，并在波恩大学癫痫数据集上验证了此方法的有效性。结果表明，多域联合特征在二分类(A-E)任务中 10 折交叉验证的平均准确率、精确率、召回率和 F 值均达到了 100%，在三分类任务中的平均准确率为 97.34%。与使用相同数据集的其他算法相比，本研究算法具有较好的分类性能。

(2)建立了一种基于注意力机制的时间卷积网络模型，用于癫痫脑电信号的分类。该模型由三个主要模块组成：卷积模块，用于将原始的 EEG 信号编码成紧凑的时间序列；多头自注意力模块，用于突出时间序列中最有效的信息；以及时间卷积模块，用于从时间序列中提取高级时间特征。此方法还实现了一种基于卷积的滑动窗口和卷积模块相结合的方法，通过并行化处理有效地提高了癫痫分类性能。结果表明，基于注意力机制的时间卷积网络模型在波恩大学癫痫数据集二分类任务中均获得了 100%的准确率，在三分类任务中 10 折交叉验证的平均准确率达到 98.67%的准确率。比较了近几年选用不同算法得到的实验结果，证明了基于注意力机制的时间卷积网络能更好地解决癫痫脑电信号状态分类问题。

本实验尚存在一些不足之处，还有很多问题需要进一步研究：

(1)多域联合分析方法仅在波恩大学癫痫数据集上进行了验证，还需要在更长持续时间和更大的数据库中进行测试。所以实现一种跨数据库的分类框架是未来研究的重点与难点。

(2)本文中使用的数据均为全频带的，没有进行频带选择，因此在数据预处理阶段加入频带选择方法选择出更适合分类的最佳频率，或许可以更进一步的精确分类结果。

(3)基于注意力机制的深度学习方法应用于癫痫分类的研究相对较少，注意力神经网络的研究还处于起步阶段，可能有更合适的变体模型适用于脑电信号分类，该领域正处在高速发展的阶段，值得深入研究。

参考文献

- [1] Stelzle D, Schmidt V, Ngowi B J, et al. Lifetime prevalence of epilepsy in urban Tanzania—A door-to-door random cluster survey[J]. *Eneurologicalsci*, 2021, 24(3): 100352.
- [2] Sazgar M, Young M G. Absolute epilepsy and EEG rotation review: Essentials for trainees[M]. California: Springer, 2019: 66-69.
- [3] Kulaseharan S, Aminpour A, Ebrahimi M, et al. Identifying lesions in paediatric epilepsy using morphometric and textural analysis of magnetic resonance images[J]. *NeuroImage: Clinical*, 2019, 21(2): 101663.
- [4] Van Klink N, Mooij A, Huiskamp G, et al. Simultaneous MEG and EEG to detect ripples in people with focal epilepsy[J]. *Clinical Neurophysiology*, 2019, 130(7): 1175-1183.
- [5] Fountas K, Kapsalaki E Z. Epilepsy surgery and intrinsic brain tumor surgery[M]. Greece: Springer, 2019: 133-136.
- [6] Lauretani F, Longobucco Y, Ravazzoni G, et al. Imaging the functional neuroanatomy of Parkinson's disease: clinical applications and future directions[J]. *International Journal of Environmental Research and Public Health*, 2021, 18(5): 2356.
- [7] Raimondo L, Heij J, Priovoulos N, et al. Advances in resting state fMRI acquisitions for functional connectomics[J]. *Neuroimage*, 2021, 243(6): 118503.
- [8] Morales Chacón L M, González González J, Ríos Castillo M, et al. Surgical outcome in extratemporal epilepsies based on multimodal pre-surgical evaluation and sequential intraoperative electrocorticography[J]. *Behavioral Sciences*, 2021, 11(3): 30.
- [9] Bernasconi A, Cendes F, Theodore W H, et al. Recommendations for the use of structural magnetic resonance imaging in the care of patients with epilepsy: a consensus report from the International League Against Epilepsy Neuroimaging Task Force[J]. *Epilepsia*, 2019, 60(6): 1054-1068.
- [10] Ahmad I, Wang X, Zhu M, et al. EEG-Based Epileptic Seizure Detection via Machine/Deep Learning Approaches: A Systematic Review[J]. *Computational Intelligence and Neuroscience*, 2022, 2022(4): 6486570.
- [11] Fisher R S. The new classification of seizures by the International League Against Epilepsy 2017[J]. *Current Neurology and Neuroscience Reports*, 2017, 17(1): 1-6.
- [12] Sharma R, Pachori R B. Classification of epileptic seizures in EEG signals based on phase space representation of intrinsic mode functions[J]. *Expert Systems with Applications*, 2015, 42(3): 1106-1117.
- [13] Usman S M, Khalid S, Bashir Z. Epileptic seizure prediction using scalp electroencephalogram

- signals[J]. Biocybernetics and Biomedical Engineering, 2021, 41(1): 211-220.
- [14] Alickovic E, Kevric J, Subasi A. Performance evaluation of empirical mode decomposition, discrete wavelet transform, and wavelet packed decomposition for automated epileptic seizure detection and prediction[J]. Biomedical Signal Processing and Control, 2018, 39(3): 94-102.
- [15] Al Ghayab H R, Li Y, Siuly S, et al. Epileptic EEG signal classification using optimum allocation based power spectral density estimation[J]. IET Signal Processing, 2018, 12(6): 738-747.
- [16] 张汉勇, 孟庆芳, 杜蕾. 基于加权复杂网络度熵和的癫痫发作检测方法[J]. 中国生物医学工程学报, 2019, 38(03): 273-280.
- [17] Zhang T, Chen W, Li M. Fuzzy distribution entropy and its application in automated seizure detection technique[J]. Biomedical Signal Processing and Control, 2018, 39(6): 360-377.
- [18] 李红利, 王江, 邓斌. 癫痫脑电的递归确定性分析[J]. 计算机应用研究, 2013, 30(03): 757-759.
- [19] Yakovleva T V, Kutepov I E, Karas A Y, et al. EEG Analysis in Structural Focal Epilepsy Using the Methods of Nonlinear Dynamics (Lyapunov Exponents, Lempel–Ziv Complexity, and Multiscale Entropy)[J]. The Scientific World Journal, 2020, 2020(2): 8407872.
- [20] Kulkarni N N, Bairagi V K. Extracting Salient Features for EEG-based Diagnosis of Alzheimer's Disease Using Support Vector Machine Classifier[J]. IETE Journal of Research, 2016, 63(1): 11-22.
- [21] Gupta V, Priya T, Yadav A K, et al. Automated detection of focal EEG signals using features extracted from flexible analytic wavelet transform[J]. Pattern Recognition Letters, 2017, 94(3): 180-188.
- [22] Chua K C, Chandran V, Acharya U R, et al. Application of higher order spectra to identify epileptic EEG[J]. J Med Syst, 2011, 35(6): 1563-1571.
- [23] Bou Assi E, Gagliano L, Rihana S, et al. Bispectrum Features and Multilayer Perceptron Classifier to Enhance Seizure Prediction[J]. Scientific Reports, 2018, 8(1): 15491.
- [24] Das A B, Bhuiyan M I H. Discrimination and classification of focal and non-focal EEG signals using entropy-based features in the EMD-DWT domain[J]. Biomedical Signal Processing and Control, 2016, 29(8): 11-21.
- [25] Zhang T, Chen W, Li M. Generalized Stockwell transform and SVD-based epileptic seizure detection in EEG using random forest[J]. Biocybernetics and Biomedical Engineering, 2018, 38(3): 519-534.
- [26] Mursalin M, Zhang Y, Chen Y, et al. Automated epileptic seizure detection using improved correlation-based feature selection with random forest classifier[J]. Neurocomputing, 2017, 241(3): 204-214.

- [27] Khan H, Marcuse L, Fields M, et al. Focal onset seizure prediction using convolutional networks[J]. IEEE Transactions on Biomedical Engineering, 2017, 65(9): 2109-2118.
- [28] Yang Y, Zhou M, Niu Y, et al. Epileptic seizure prediction based on permutation entropy[J]. Frontiers in Computational Neuroscience, 2018, 12(6): 55.
- [29] Daoud H, Bayoumi M A. Efficient epileptic seizure prediction based on deep learning[J]. IEEE transactions on biomedical circuits and systems, 2019, 13(5): 804-813.
- [30] Bhattacharyya A, Pachori R B, Upadhyay A, et al. Tunable-Q wavelet transform based multiscale entropy measure for automated classification of epileptic EEG signals[J]. Applied Sciences, 2017, 7(4): 385.
- [31] 宋玉龙, 赵冕, 郑威. 基于经验模态分解和极限学习机的癫痫脑电提取分类研究[J]. 生物医学工程研究, 2019, 38(03): 263-268.
- [32] Chen S, Zhang X, Chen L, et al. Automatic diagnosis of epileptic seizure in electroencephalography signals using nonlinear dynamics features[J]. IEEE Transactions on Biomedical Engineering, 2019, 7(6): 61046-61056.
- [33] Thara D, Premasudha B, Xiong F. Epileptic seizure detection and prediction using stacked bidirectional long short term memory[J]. Pattern Recognition Letters, 2019, 128(9): 529-535.
- [34] Acharya U R, Oh S L, Hagiwara Y, et al. Deep convolutional neural network for the automated detection and diagnosis of seizure using EEG signals[J]. Computers in biology and medicine, 2018, 100(12): 270-278.
- [35] Truong N D, Nguyen A D, Kuhlmann L, et al. Convolutional neural networks for seizure prediction using intracranial and scalp electroencephalogram[J]. Neural Networks, 2018, 105(3): 104-111.
- [36] Zhang Y, Guo Y, Yang P, et al. Epilepsy seizure prediction on EEG using common spatial pattern and convolutional neural network[J]. Ieee Journal of Biomedical and Health Informatics, 2019, 24(2): 465-474.
- [37] Ullah I, Hussain M, Aboalsamh H. An automated system for epilepsy detection using EEG brain signals based on deep learning approach[J]. Expert Systems with Applications, 2018, 107(6): 61-71.
- [38] Mian Qaisar S, Subasi A. Effective epileptic seizure detection based on the event-driven processing and machine learning for mobile healthcare[J]. Journal of Ambient Intelligence and Humanized Computing, 2022, 13(7): 3619-3631.
- [39] 陈多. 基于小波变换的癫痫脑电信号分析[D]. 南京: 东南大学博士论文, 2017: 3-6.
- [40] Martis R J, Acharya U R, Lim C M, et al. Application of higher order cumulant features for cardiac health diagnosis using ECG signals[J]. International Journal of Neural Systems, 2013, 23(04): 1350014.

-
- [41] Bartolomei F, Lagarde S, Wendling F, et al. Defining epileptogenic networks: contribution of SEEG and signal analysis[J]. *Epilepsia*, 2017, 58(7): 1131-1147.
- [42] Herff C, Krusienski D J, Kubben P. The potential of stereotactic-EEG for brain-computer interfaces: current progress and future directions[J]. *Frontiers in Neuroscience*, 2020, 14(2): 123.
- [43] Cherian R, Kanaga E G. Theoretical and methodological analysis of EEG based seizure detection and prediction: An exhaustive review[J]. *J Neurosci Methods*, 2022, 369(6): 109483.
- [44] Wu Q, Zeng Y, Zhang C, et al. An EEG-based person authentication system with open-set capability combining eye blinking signals[J]. *Sensors*, 2018, 18(2): 335.
- [45] Chen Y, Atnafu A D, Schlattner I, et al. A high-security EEG-based login system with RSVP stimuli and dry electrodes[J]. *IEEE Transactions on Information Forensics and Security*, 2016, 11(12): 2635-2647.
- [46] Zhang S, Sun L, Mao X, et al. Review on EEG-Based Authentication Technology[J]. *Comput Intell Neurosci*, 2021, 2021(12): 5229576.
- [47] Kumar Y, Dewal M, Anand R S. Epileptic seizure detection using DWT based fuzzy approximate entropy and support vector machine[J]. *Neurocomputing*, 2014, 133(10): 271-279.
- [48] Roy Y, Banville H, Albuquerque I, et al. Deep learning-based electroencephalography analysis: a systematic review[J]. *Journal of Neural Engineering*, 2019, 16(5): 051001.
- [49] Hossain M S, Amin S U, Alsulaiman M, et al. Applying deep learning for epilepsy seizure detection and brain mapping visualization[J]. *ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM)*, 2019, 15(1s): 1-17.
- [50] Zuo R, Wei J, Li X, et al. Automated detection of high-frequency oscillations in epilepsy based on a convolutional neural network[J]. *Frontiers in Computational Neuroscience*, 2019, 13(1): 6.
- [51] Asif U, Roy S, Tang J, et al. Machine Learning in Clinical Neuroimaging and Radiogenomics in Neuro-Oncology [M]. Springer International Publishing, 2020: 36-39.
- [52] Covert I, Krishnan B, Najm I M, et al. Temporal Graph Convolutional Networks for Automatic Seizure Detection[J]. *arXiv preprint arXiv:19.5.01375*, 2019, <https://arxiv.org/abs/1905.01375>.
- [53] Chaari L. Digital Health Approach for Predictive, Preventive, Personalised and Participatory Medicine[M]. Tunisia: Springer, 2019: 6-9.
- [54] Jiang C, Zhou Q, Lei J, et al. A Two-Stage Structural Damage Detection Method Based on 1D-CNN and SVM[J]. *Applied Sciences*, 2022, 12(20): 10394.
- [55] Talathi S S. Deep Recurrent Neural Networks for seizure detection and early seizure detection systems[J]. *arXiv preprint arXiv:1706.03283*, 2017, <https://arxiv.org/abs/1706.03283>.
- [56] Ieřmantas T, Alzbutas R. Convolutional neural network for detection and classification of seizures in clinical data[J]. *Medical & Biological Engineering & Computing*, 2020, 58(6): 1919-1932.

- [57] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30(1): 1-3.
- [58] Wang Z, Wang Y, Hu C, et al. Transformers for EEG-based emotion recognition: A hierarchical spatial information learning model[J]. IEEE Sensors Journal, 2022, 22(5): 4359-4368.
- [59] Kim D, Lee J, Woo Y, et al. Deep learning application to clinical decision support system in sleep stage classification[J]. Journal of Personalized Medicine, 2022, 12(2): 136.
- [60] Bagchi S, Bathula D R. EEG-ConvTransformer for single-trial EEG-based visual stimulus classification[J]. Pattern Recognition, 2022, 129(12): 108757.
- [61] Tao Y, Sun T, Muhamed A, et al. Gated transformer for decoding human brain EEG signals[C]// Gated transformer for decoding human brain EEG signals. 2021 43rd Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC), Guadalajara, Mexico. 2021: 125-130.
- [62] Delorme A, Makeig S. EEGLAB: an open source toolbox for analysis of single-trial EEG dynamics including independent component analysis[J]. Journal of Neuroscience Methods, 2004, 134(1): 9-21.
- [63] Andrzejak R G, Lehnertz K, Mormann F, et al. Indications of nonlinear deterministic and finite-dimensional structures in time series of brain electrical activity: dependence on recording region and brain state[J]. Phys Rev E Stat Nonlin Soft Matter Phys, 2001, 64(6): 061907.
- [64] Gui J, Sun Z, Ji S, et al. Feature Selection Based on Structured Sparsity: A Comprehensive Study[J]. IEEE Transactions on Neural Networks and Learning Systems, 2017, 28(7): 1490-1507.
- [65] Zhou H, Zhang J, Zhou Y, et al. A feature selection algorithm of decision tree based on feature weight[J]. Expert Systems with Applications, 2021, 164(3): 113842.
- [66] Jing J, Pang X, Pan Z, et al. Classification and identification of epileptic EEG signals based on signal enhancement[J]. Biomedical Signal Processing and Control, 2022, 71(10): 103248.
- [67] Nabil D, Benali R, Reguig F B. Epileptic seizure recognition using EEG wavelet decomposition based on nonlinear and statistical features with support vector machine classification[J]. Biomedical Engineering-Biomedizinische Technik, 2020, 65(2): 133-148.
- [68] Tuncer T, Dogan S, Ertam F, et al. A novel ensemble local graph structure based feature extraction network for EEG signal analysis[J]. Biomedical Signal Processing and Control, 2020, 61(9): 102006.
- [69] Raghu S, Sriraam N, Hegde A S, et al. A novel approach for classification of epileptic seizures using matrix determinant[J]. Expert Systems with Applications, 2019, 127(8): 323-341.
- [70] Chandel G, Upadhyaya P, Farooq O, et al. Detection of Seizure Event and Its Onset/Offset Using Orthonormal Triadic Wavelet Based Features[J]. Irbm, 2019, 40(2): 103-112.

- [71] Sharmila A, Geethanjali P. Effect of filtering with time domain features for the detection of epileptic seizure from EEG signals[J]. Journal of Medical Engineering & Technology, 2018, 42(3): 217-227.
- [72] Bahdanau D, Cho K, Bengio Y. Neural Machine Translation by Jointly Learning to Align and Translate[J]. arXiv preprint arXiv:1409.0473, 2014. <https://arxiv.org/abs/1409.0473>.
- [73] Luong T, Pham H, Manning C D. Effective Approaches to Attention-based Neural Machine Translation[C]//Empirical Methods Natural Language Processing (EMNLP), Lisbon, Portugal, 2015: 1412–1421..
- [74] Zhang D, Chen K, Jian D, et al. Motor imagery classification via temporal attention cues of graph embedded EEG signals[J]. Ieee Journal of Biomedical and Health Informatics, 2020, 24(9): 2570-2579.
- [75] Altuwaijri G A, Muhammad G, Altaheri H, et al. A multi-branch convolutional neural network with squeeze-and-excitation attention blocks for eeg-based motor imagery signals classification[J]. Diagnostics, 2022, 12(4): 995.
- [76] Lawhern V J, Solon A J, Waytowich N R, et al. EEGNet: a compact convolutional neural network for EEG-based brain–computer interfaces[J]. Journal of Neural Engineering, 2018, 15(5): 056013.
- [77] Schirrneister R T, Springenberg J T, Fiederer L D J, et al. Deep learning with convolutional neural networks for EEG decoding and visualization[J]. Human brain mapping, 2017, 38(11): 5391-5420.
- [78] Ingolfsson T M, Hersche M, Wang X, et al. EEG-TCNet: An Accurate Temporal Convolutional Network for Embedded Motor-Imagery Brain–Machine Interfaces[C]// EEG-TCNet: An Accurate Temporal Convolutional Network for Embedded Motor-Imagery Brain–Machine Interfaces. 2020, IEEE International Conference on Systems, Man, and Cybernetics (SMC), Toronto, ON, Canada, 2020. 2958-2965.
- [79] Khan P, Khan Y, Kumar S, et al. HVD-LSTM based recognition of epileptic seizures and normal human activity[J]. Computers in biology and medicine, 2021, 136(9): 104684.
- [80] Ilakiyaselvan N, Khan A N, Shahina A. Deep learning approach to detect seizure using reconstructed phase space images[J]. Journal of Biomedical Research, 2020, 34(3): 240.
- [81] Thara D K, Premasudha B G, Xiong F. Epileptic seizure detection and prediction using stacked bidirectional long short term memory[J]. Pattern Recognition Letters, 2019, 128(6): 529-535.
- [82] Acharya U R, Hagiwara Y, Deshpande S N, et al. Characterization of focal EEG signals: A review[J]. Future Generation Computer Systems, 2019, 91(8): 290-299.
- [83] Ahmedt-Aristizabal D, Fookes C, Nguyen K, et al. Deep Classification of Epileptic Signals[C]// Deep Classification of Epileptic Signals. 2018 40th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC), Honolulu, HI, USA, 2018, 332-335.